

DOCE 102 - Computación Estadística

Ejercicios Optimización

Nicolás Rivera
Universidad de Valparaíso

Ejercicio 1. Considere la siguiente función objetivo

$$f(\beta) = \frac{1}{2}\|y - X\beta\|_2^2 + \frac{\lambda}{2}\|\beta\|_2^2$$

donde $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$ es una matrix, y $\lambda \in \mathbb{R}$ con $\lambda > 0$ también es conocido. Lo único variable es $\beta \in \mathbb{R}^p$.

1. Calcule el gradiente $\nabla f(\beta)$. Calcule la matriz Hessiana $\nabla^2 f(\beta)$.
2. Encuentre el punto crítico β^*
3. Usando el criterio del Hessiano, demuestre rigurosamente que β^* es un mínimo global y argumente por qué la solución es única (incluso si $p > n$).

Ejercicio 2. Para cada una de las siguientes funciones de dos variables, determine el vector gradiente, encuentre todos los puntos críticos, calcule la matriz Hessiana y clasifique cada punto crítico (como mínimo local, máximo local o punto de silla) utilizando el criterio de la segunda derivada. Muestre su desarrollo.

1. $f(x, y) = x^4 + y^4 - 4xy$
2. $g(x, y) = (x^2 + y^2)e^{-x}$

Ejercicio 3. Suponga que deseamos encontrar un vector de parámetros $x \in \mathbb{R}^p$ que minimice el riesgo esperado de un modelo predictivo. La función objetivo teórica está dada por:

$$F(x) = \mathbb{E}_{Y \sim P} \left[\log(1 + e^{-x^T Y}) \right] + \frac{\lambda}{2}\|x\|_2^2 \quad (1)$$

donde $x \in \mathbb{R}^p$ es el vector a optimizar, $Y \in \mathbb{R}^p$ es un vector aleatorio que sigue una distribución multivariada P , y $\lambda > 0$ es un parámetro de regularización fijo.

Debido a la complejidad de la distribución P , la integral que define el valor esperado de la pérdida logística no tiene solución analítica, por lo que es imposible evaluar $F(x)$ directamente. Sin embargo, es computacionalmente barato simular muestras aleatorias independientes de P .

1. Escriba un estimador de montecarlo $\hat{F}_n$ para $F(x)$, donde n representa el número de muestras de Montecarlo de P .
2. Muestre que $\nabla \hat{F}_n(x)$ es un estimador insesgado de $\nabla F(x)$. Para ello puede que necesite intercambiar $\mathbb{E}$ con ∇ . Investigue condiciones para poder justificar el intercambio.

3. Escriba el pseudo código para el algoritmo de gradient descend. Discuta: Intuitivamente ¿es conveniente resamplear las n muestras de P en cada iteración, o es mejor tener una muestra al inicio y no cambiarla durante el algoritmo?

Ejercicio 4. Considere una secuencia de parámetros generada por la función iterativa $T : \mathbb{R} \rightarrow \mathbb{R}$, definida por la regla de actualización:

$$x_{k+1} = T(x_k) = \frac{1}{3}x_k + 4$$

Asuma la métrica estándar euclidiana $d(x, y) = |x - y|$ y suponga que inicializamos el algoritmo en el punto $x_0 = 0$.

1. Demuestre formalmente que T es una función contractiva en $\mathbb{R}$ e identifique el valor de su constante de Lipschitz L (la constante $L < 1$ que logra $|T(x) - T(y)| \leq L|x - y|$)
2. Calcule analíticamente el punto fijo x^* al que convergerá la secuencia.
3. Sabiendo que $x^* = T(x^*)$ y utilizando únicamente la propiedad de contracción del operador, demuestre iterativamente (desarrollando los términos desde x_n hasta x_0) que la distancia entre la aproximación en la iteración n y el punto fijo está acotada por:

$$d(x_n, x^*) \leq L^n d(x_0, x^*)$$

4. Suponga que necesita que la aproximación de su algoritmo tenga un error máximo garantizado de $\epsilon = 10^{-4}$. Utilizando la cota teórica derivada en el inciso anterior, determine el número mínimo de iteraciones n que el computador debe ejecutar para asegurar matemáticamente que $d(x_n, x^*) < 10^{-4}$.

Ejercicio 5. Considere la función $f : [1, \infty) \rightarrow [1, \infty)$ definida por:

$$f(x) = x + \frac{1}{x} \tag{2}$$

1. Demuestre que la función es estrictamente no expansiva en $[1, \infty)$. Es decir, compruebe que para cualquier par de puntos distintos $x, y \in [1, \infty)$, se cumple la desigualdad estricta:

$$|f(x) - f(y)| < |x - y|$$

pero que para todo $L < 1$ existen un par $x, y \in [1, \infty)$ tal que $|f(x) - f(y)| > L|x - y|$.

2. A pesar de cumplir la condición anterior, demuestre analíticamente que f **no** tiene ningún punto fijo en $[1, \infty)$.
3. ¿Por qué este resultado no contradice el Teorema del Punto Fijo de Banach? Explique qué hipótesis clave del teorema falla en este caso particular.

Ejercicio 6. Encuentre:

- 1.

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x, y, z) = x^2 + y^2 + 2z^2 \\ \text{sujeto a} \quad & x + 2y + z = 11 \end{aligned}$$

2.

$$\begin{aligned} \max_{x,y,z \in \mathbb{R}} \quad & f(x,y,z) = 2x + y - 2z \\ \text{sujeto a} \quad & x^2 + y^2 + z^2 = 9 \end{aligned}$$

Ejercicio 7. En el Estadística, Machine Learning, y Mecánica Estadística, el principio de Máxima Entropía establece que la distribución de probabilidad que mejor representa nuestro estado actual de conocimiento es aquella que maximiza la entropía, sujeta a restricciones conocidas.

Considere una variable aleatoria discreta X que toma valores en un conjunto finito $\mathcal{X} = \{x_1, x_2, \dots, x_k\}$ y conocido. Queremos encontrar la función de masa de probabilidad $p = (p_1, \dots, p_k)$ que maximice la entropía de Shannon:

$$H(p) = - \sum_{i=1}^k p_i \log p_i$$

sujeta a dos restricciones:

- La normalización de probabilidades: $\sum_{i=1}^k p_i = 1$.
- El valor esperado de la distribución es conocido: $\sum_{i=1}^k p_i x_i = \mu$.

Así

1. Encuentre $(p_1, \dots, p_k)$ que maximicen la entropía de Shannon sujeta a las restricciones anteriores
2. Encuentre $(p_1, \dots, p_k)$ que maximicen la entropía de Shannon sujeta a las restricciones anteriores pero además sujeta a la restricción $\sum_{i=1}^k p_i x_i^2 = \gamma$ (es decir, conociendo la media y el segundo momento de p)
3. En los casos anteriores, a pesar de ser probabilidades discretas, ¿qué modelos puede reconocer?

Nota: esto se llama principio de máxima entropía, que al parecer tiene justificaciones teóricas y prácticas de porque es el procedimiento correcto para justificar modelos probabilísticos.

Ejercicio 8. Considere el problema

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) = \frac{1}{2} x^T Q x - c^T x \\ \text{sujeto a} \quad & Ax = b \end{aligned}$$

donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica y estrictamente definida positiva, $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$ es una matriz de restricciones de rango fila completo ($m < n$), y $b \in \mathbb{R}^m$.

1. Explique por qué el Lagrangiano está dado por $\mathcal{L}(x, \lambda) = \frac{1}{2} x^T Q x - c^T x + \lambda^t (Ax - b)$ donde $\lambda \in \mathbb{R}^d$
2. Resuelva el problema de minimización encontrando el vector x^* que minimiza f sujeta a la restricción.

Ejercicio 9. Suponga que tiene un conjunto de datos de conteo $D = \{(x_1, y_1), \dots, (x_n, y_n)\}$, donde $x_i \in \mathbb{R}^p$ son las covariables y $y_i \in \mathbb{N}_0$ es la variable de respuesta. Asumimos que y_i sigue una distribución de Poisson con un parámetro de tasa λ_i modelado mediante una función de enlace logarítmica:

$$\lambda_i = \exp(x_i^T \beta)$$

donde $\beta \in \mathbb{R}^p$ es el vector de parámetros que deseamos estimar.

1. Escriba la likelihood $L(\beta|D)$ y calcule la log-likelihood $\ell(\beta|D)$
2. Encuentre el gradiente y hessiado de $\ell(\beta|D)$
3. Escriba un pseudo-código del algoritmo de Gradient Descent (o ascenso en este caso) para encontrar β^* que maximiza $\ell(\beta|D)$.
4. A diferencia de la Regresión Lineal Ordinaria o la Regresión Logística, el uso de un tamaño de paso constante α en la Regresión de Poisson es numéricamente muy peligroso. Analizando la estructura de la matriz Hessiana que acaba de derivar, explique matemáticamente por qué el Descenso de Gradiente estándar es propenso a divergir (explotar) en este modelo, y proponga una estrategia algorítmica para solucionarlo.