

Tarea 3

Fecha de Entrega: Viernes 10 de Julio de 2025 a las 18:00:00

Instrucciones:

1. Debe entregar la tarea en el buzón de la Tarea 3 en el Aula Virtual.
2. Su tarea debe contener un informe en PDF, idealmente escrito en $\text{\LaTeX}$. Donde se expliquen sus ideas, y justifique las decisiones que tomó al escribir sus programas. Usted debe además siempre explicar, formalmente, porque sus programas funcionan. No es necesario enviar código en esta tarea, ya que no hay mucho código que escribir.
3. Está permitido trabajar con sus compañeros para la resolución de los problemas, pero cada uno debe escribir sus propias respuestas (sin ayuda). Junto con sus respuestas escriba el nombre de los compañeros con quién trabajó en la resolución.
4. Pueden hacerme consultas razonables en persona o por e-mail. La calidad de las respuestas empieza a disminuir a medida que se acerca el plazo de entrega. La calidad de la respuesta también depende de que tan bien pensada está su pregunta. Por ejemplo: preguntas del tipo "No sé por donde partir, ¿qué hago?" serán ignoradas. Preguntas del tipo "Encontré este artículo que resuelve un problema parecido, creo que es relevante, sin embargo no entiendo como implementar esta parte, ¿me ayuda?" son más razonables y esperables a nivel de doctorado.
5. Está permitido usar la internet, chats varios, etc. **Incluya su fuente en el informe, y verifique que la información obtenida sea pertinente.** Si usted incluye ideas que no hemos visto en clases, entonces debe explicar, formalmente porque funcionan. Por ejemplo si quiere usar un algoritmo X , usted debe explicar y fundamentar el algoritmo X (es decir, debe estudiarlo y explicarlo.)

NOTA ESPECIAL: en esta tarea no hay ejercicios que involucren investigación o problemas inventados a la pasada, por lo que son problemas más estándares (que no significa que sean fáciles). Probablemente la respuesta está en la internet, y probablemente los chat ya fueron entrenados con esta información. Si quieren aprender bien y ser capaces de llegar a la punta de la montaña de la Computación Estadística, yo recomiendo minimizar el uso de internet a definiciones, y a resultados conocidos que quizás no manejen bien (e.g. teoremas de cálculo, álgebra lineal o probabilidad). Los problemas son bastante conceptuales, así que involucran pensar y meditar. Si no quieren, no hay problema, pueden usar chats y cosas varias.

Problema 1 (30 puntos, 5 puntos cada parte). Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria independiente e idénticamente distribuida (i.i.d.) proveniente de una distribución Uniforme en el intervalo $[0, \theta_0]$, donde $\theta_0 > 0$ es un parámetro desconocido. Sabemos que el estimador de máxima verosimilitud para la cota superior es el máximo muestral, dado por $\hat{\theta}_n = \max_{1 \leq i \leq n} X_i$.

1. **Distribución asintótica verdadera:** Demuestre matemáticamente que la variable aleatoria reescalada $n \frac{\theta_0 - \hat{\theta}_n}{\theta_0}$ converge en distribución a una variable aleatoria Exponencial con media 1. Es decir, demuestre que

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(n \frac{\theta_0 - \hat{\theta}_n}{\theta_0} < x \right) = 1 - e^{-x}.$$

2. Obtenga intervalo de confianza para θ_0 de confianza $1 - \alpha$. Note que evidentemente $\theta_0 \geq \hat{\theta}_n$, así que el intervalo de confianza debe tener a $\hat{\theta}_n$ como límite inferior
3. Evidentemente, no necesitamos bootstrap para hacer este problema ya que tenemos la distribución asintótica del estadístico, pero supongamos por un momento que no la conocemos y queremos hacer bootstrap. Explique brevemente porque generar muestras de bootstrap de Efron para construir un intervalo de forma empírica, no ayuda en nada. (Recuerde que en Bootstrap de Efron extraemos una muestra $X_1^*, \dots, X_n^*$ de tamaño n con reemplazo desde la muestra original y calculamos su máximo, llamado $\hat{\theta}_n^*$)
4. Supongamos que queremos simular de la distribución de $n \frac{\theta_0 - \hat{\theta}_n}{\theta_0}$, para ello se propone simular de $n \frac{\hat{\theta}_n - \hat{\theta}_n^*}{\hat{\theta}_n}$. Muestre que dicha variable aleatoria no tiene una distribución cercana a una exponencial de media 1, para ello demuestre que, a medida que $n \rightarrow \infty$, la probabilidad de que el estimador bootstrap $\hat{\theta}_n^*$ sea exactamente igual al estimador original $\hat{\theta}_n$ converge a $1 - e^{-1}$. Es decir, demuestre que:

$$\lim_{n \rightarrow \infty} P(\hat{\theta}_n^* = \hat{\theta}_n) = 1 - e^{-1} \approx 0.632,$$

y concluya.

5. **Subsampling.** Para solucionar el problema anterior se propone el método de subsampling: extraemos una muestra $X_1^*, \dots, X_b^*$ con reemplazo, donde $b = \lfloor n^{3/4} \rfloor$.

Condicionado en los datos $X_1, \dots, X_n$, demuestre que

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(b \frac{\hat{\theta}_n - \hat{\theta}_n^*}{\hat{\theta}_n} < x \middle| X_1, \dots, X_n \right) = 1 - e^{-x}.$$

Ayuda: Note que la aleatoriedad es solo en el remuestreo. La probabilidad se puede calcular de forma exacta, pero le quedará una expresión que depende en $X_1, \dots, X_n$, (probablemente a través de $\hat{\theta}_n$). Una vez que obtenga una expresión razonable para la probabilidad, puede calcular el límite usando que $\hat{\theta}_n$ es un estimador consistente de θ_0 , y quizás algunos resultados que han aprendido en teoría de probabilidad.

6. Eliga n suficientemente grande, θ_0 a gusto. Simule $X_1, \dots, X_n$ i.i.d. de uniformes $[0, \theta_0]$, y a partir de M muestras de subsampling con $b = \lfloor n^{3/4} \rfloor$ muestre experimentalmente que

$$b \frac{\hat{\theta}_n - \hat{\theta}_n^*}{\hat{\theta}_n}$$

tiene distribución, aproximadamente, exponencial de media 1. ¿Qué tan grande tiene que ser n para que este método de bootstrapping funcione?

Nota: subsampling es una técnica que puede ser usada para casos donde bootstrap clásico falla. Saber cuando una cosa falla es más complicado, en especial cuando dejamos modelos de juguete como el de esta tarea. Eso requiere especializarse aún más en el mundo de bootstrap

Problema 2 (30 puntos, 3 puntos cada parte). Recuerde que la norma Euclidiana de un vector $x \in \mathbb{R}^d$ está dada por $\|x\|_2 = \sqrt{\sum_{i=1}^d x_i^2}$. Para una matrix $A \in \mathbb{R}^{d \times d}$, definimos la norma Euclidiana de A como

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}$$

Recuerde que λ es un vector propio de A si existe $x \in \mathbb{R}^d$ tal que $Ax = \lambda x$. También, recuerde que si A es simétrica entonces el teorema espectral nos dice que existen d pares de valores y vectores propios (λ_i, x_i) tales que $Ax_i = \lambda_i x_i$ y de tal forma que $\{x_1, \dots, x_d\}$ forman una base ortonormal de $\mathbb{R}^d$, es decir $\langle x_i, x_j \rangle = 0$ para $i \neq j$, donde $\langle \cdot, \cdot \rangle$ denota el producto punto usual (recuerde que $\langle x_i, x_i \rangle = \|x_i\|_2^2$).

1. Demuestre que para una matriz simétrica se tiene que $\|A\|_2 = \max_{i \in \{1, \dots, d\}} |\lambda_i|$ donde λ_i son los valores propios de la matriz A . Para ello descomponga x como $x = \sum_{i=1}^d \langle x_i, x \rangle x_i$.
2. Sea A una matriz simétrica con valores propios $\lambda_1, \dots, \lambda_n$. Verifique que los valores propios de $I - \alpha A$ son $1 - \alpha \lambda_i$.
3. Sea $f : \mathbb{R}^d \rightarrow \mathbb{R}$ una función y considere el método de descenso de gradiente, dado por la transformación

$$T(x) = x - \gamma \nabla f(x),$$

donde $\gamma > 0$ es el tamaño del salto. Usando el teorema del valor medio (de cálculo), muestre que existe un punto c en la línea recta que une x e y tal que

$$T(x) - T(y) = (JT)(c)$$

donde JT es el Jacobiano de T .

4. Muestre que $JT = I - \gamma Hf$ donde Hf es el Hacobiano de f .
5. Concluya que $\|T(x) - T(y)\|_2 = \|I - \gamma(Hf)(c)\|_2$
6. Supponga que el Hacobiano Hf es tal que $m \leq \|Hf(x)\|_2 \leq M$ para dos constantes m y M con $m > 0$, demuestre que para $\gamma \in (0, 2/M)$ se tiene que T es una contracción, es decir, $\|T(x) - T(y)\|_2 \leq L\|x - y\|_2$ con $L = \max(|1 - \gamma M|, |1 - \gamma m|)$.
7. Encuentre γ que encuentre minimise L .
8. Usando el Teorema del Punto Fijo de Banach, concluya que gradient descent converge al único punto fijo de T .
9. Suponga que x_∞ es el punto fijo, y que x_0 es su punto inicial del algoritmo. Defina $x_n = T(x_{n-1})$, muestre que $\|x_n - x_\infty\| \leq L^k \|x_0 - x_\infty\|$, y por lo tanto, si queremos $\|x_n - x_\infty\| < \varepsilon$, entonces necesitamos

$$n \geq \frac{\log\left(\frac{\varepsilon}{\|x_0 - x_\infty\|_2}\right)}{\log(L)}$$

Nota: lo anterior se llama *convergencia lineal* ya que nos dice que si queremos un error $\varepsilon = 1/10^k$ entonces el algoritmo necesita una cantidad proporcional a k pasos para obtener dicho error. Esto justifica gran parte del éxito de descenso de gradiente: si quiero 5 decimales de precisión en mi optimización solo tengo que hacer 5 veces el esfuerzo que hubiese hecho para obtener 1 decimal, más un esfuerzo inicial (que depende de la distancia inicial entre x_0 y x_∞)

10. Escriba el método de gradient descent para optimizar $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, dada por

$$f(x) = \frac{1}{2}(x_1^2 + 100x_2^2).$$

Basado en lo estudiado en las partes anteriores, qué tamaño de paso debe elegir en gradient descent? Explique que ocurre con su algoritmo si dicha condición no se satisface, muestre ejemplos numéricos para ejemplificar sus observaciones.