Universidad de Valparaíso
DOCE-202 Computación Estadística II
Semestre II 2026.
Profesor: Nicolás Rivera

Pauta de la Prueba 1

Soluciones breves

Problema 1. Sea $X_1, \ldots, X_n$ una muestra aleatoria independiente proveniente de una distribución

$$X_i \sim N(\mu, \sigma^2),$$

donde tanto μ como σ^2 son desconocidos.

1. Calcule el gradiente de la log-verosimilitud con respecto a los parámetros (μ, σ^2).
2. Calcule la matriz Hessiana de la log-verosimilitud.
3. Encuentre los estimadores de máxima verosimilitud de μ y σ^2.
4. Utilice la matriz Hessiana para verificar que el punto obtenido corresponde a un máximo.

Pauta. Escriba $s = \sigma^2 > 0$ y $S(\mu) = \sum_{i=1}^n (X_i - \mu)^2$. Entonces

$$\ell(\mu, s) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log s - \frac{S(\mu)}{2s}.$$

1. El gradiente, respecto de (μ, s), es

$$\boxed{\nabla \ell(\mu, s) = \begin{pmatrix} s^{-1}\sum_i (X_i - \mu) \\ -\dfrac{n}{2s} + \dfrac{S(\mu)}{2s^2} \end{pmatrix}.}$$

2. La matriz Hessiana es

$$\boxed{\nabla^2 \ell(\mu, s) = \begin{pmatrix} -\dfrac{n}{s} & -\dfrac{\sum_i (X_i - \mu)}{s^2} \\ -\dfrac{\sum_i (X_i - \mu)}{s^2} & \dfrac{n}{2s^2} - \dfrac{S(\mu)}{s^3} \end{pmatrix}.}$$

3. Al igualar el gradiente a cero se obtiene, si $S(\bar{X}) > 0$,

$$\boxed{\widehat{\mu} = \bar{X}, \qquad \widehat{s} = \widehat{\sigma^2} = \frac{1}{n}\sum_{i=1}^n (X_i - \bar{X})^2.}$$

El denominador es n, pues se trata del estimador de máxima verosimilitud.

4. En este punto,
$$\nabla^2 \ell(\widehat{\mu}, \widehat{s}) = \begin{pmatrix} -n/\widehat{s} & 0 \\ 0 & -n/(2\widehat{s}^2) \end{pmatrix}$$
es definida negativa, por lo que el punto es un máximo local estricto. Es también el único máximo global: la identidad $S(\mu) = S(\bar{X}) + n(\mu - \bar{X})^2$ muestra que, para cada s, el máximo en μ está en $\bar{X}$; además,
$$\frac{d}{ds}\ell(\bar{X}, s) = \frac{S(\bar{X}) - ns}{2s^2}$$
es positiva para $s < \widehat{s}$ y negativa para $s > \widehat{s}$.

Caso degenerado. Si $S(\bar{X}) = 0$ (en particular, si $n = 1$), $\ell(\bar{X}, s) \to +\infty$ cuando $s \downarrow 0$ y no existe un máximo con $s > 0$. Para $n \geq 2$, este caso tiene probabilidad cero bajo el modelo.

Problema 2. Sea $f(t) = at^2/2$, con $a > 0$. Considere el método de descenso de gradiente con paso constante $\gamma > 0$, iniciado en $t_0 \neq 0$:
$$t_{k+1} = t_k - \gamma f'(t_k), \qquad k = 0, 1, \ldots.$$

1. Encuentre el único minimizador global de f y obtenga una expresión explícita para t_k en términos de t_0, a y γ.

2. Determine todos los valores de $\gamma > 0$ para los cuales t_k converge al minimizador. Describa qué ocurre cuando $\gamma = 1/a$ y cuando $\gamma = 2/a$.

3. Aplique el lema de descenso del anexo con $L = a$ para demostrar que
$$f(t_{k+1}) \leq f(t_k) - \gamma\left(1 - \frac{a\gamma}{2}\right)|f'(t_k)|^2.$$
¿Para qué valores de γ garantiza esta desigualdad un descenso estricto cuando $t_k \neq 0$? Compare con el intervalo de convergencia obtenido anteriormente.

4. Escriba la actualización del método de Newton con paso completo y demuestre que alcanza el minimizador en una iteración desde cualquier punto inicial. ¿A qué elección de γ corresponde en este ejemplo?

Pauta.

1. Como $f(t) \geq 0$, con igualdad únicamente en $t = 0$, el único minimizador global es $t^* = 0$. Además, $f'(t) = at$, de modo que
$$t_{k+1} = (1 - a\gamma)t_k, \qquad \boxed{t_k = (1 - a\gamma)^k t_0.}$$

2. Puesto que $t_0 \neq 0$, la convergencia a cero equivale a $|1 - a\gamma| < 1$. Por tanto,
$$\boxed{t_k \longrightarrow 0 \quad \Longleftrightarrow \quad 0 < \gamma < 2/a.}$$
Si $\gamma = 1/a$, se tiene $t_1 = 0$ y los iterados siguientes son cero. Si $\gamma = 2/a$, entonces $t_k = (-1)^k t_0$, sin convergencia. Para $\gamma > 2/a$, $|t_k| \to \infty$.

3. El gradiente es Lipschitz con constante a, pues $|f'(x) - f'(y)| = a|x - y|$. Aplique el lema con $y = t_k$ y $x = t_{k+1} = t_k - \gamma f'(t_k)$:
$$\begin{aligned} f(t_{k+1}) &\leq f(t_k) + f'(t_k)(-\gamma f'(t_k)) + \frac{a}{2}\gamma^2 |f'(t_k)|^2 \\ &= f(t_k) - \gamma\left(1 - \frac{a\gamma}{2}\right)|f'(t_k)|^2. \end{aligned}$$
Si $t_k \neq 0$, entonces $|f'(t_k)|^2 > 0$; la cota garantiza descenso estricto exactamente cuando $0 < \gamma < 2/a$. Este es también el intervalo de convergencia. En este ejemplo, la desigualdad es una igualdad, por ser f cuadrática.

4. Como $f''(t) = a > 0$, Newton está bien definido y

$$\boxed{t_{k+1} = t_k - \frac{f'(t_k)}{f''(t_k)} = t_k - \frac{at_k}{a} = 0.}$$

Alcanza el minimizador en una iteración y coincide con descenso de gradiente con $\gamma = 1/a$.

Problema 3. Sea $X \in \mathbb{R}^{n\times(p+1)}$, con $n \geq 1$, una matriz cuya primera columna está formada por unos. Las demás columnas pueden ser linealmente dependientes. Para $y \in \mathbb{R}^n$, $\lambda > 0$ y $P = \operatorname{diag}(0, 1, \ldots, 1)$, considere el objetivo de regresión Ridge

$$F(\beta) = \frac{1}{2n}\|y - X\beta\|_2^2 + \frac{\lambda}{2}\beta^\top P\beta, \qquad \beta = (\beta_0, \beta_1, \ldots, \beta_p)^\top.$$

El intercepto β_0 no se penaliza.

1. Calcule el gradiente y la matriz Hessiana de F. Deduzca las ecuaciones que debe satisfacer un minimizador.

2. Demuestre que
$$v^\top(X^\top X + n\lambda P)v > 0 \qquad \text{para todo } v \in \mathbb{R}^{p+1} \setminus \{0\}.$$
Concluya que existe un único minimizador global, incluso si las columnas de X son linealmente dependientes, y encuentre una expresión para él.

3. Suponga que cada columna de predictores está centrada, es decir, $\sum_{i=1}^n X_{ij} = 0$ para $j = 1, \ldots, p$. Demuestre que el intercepto estimado es $\widehat{\beta}_0 = \bar{y}$, donde $\bar{y} = n^{-1}\sum_{i=1}^n y_i$. ¿Cuál sería el intercepto estimado si también se penalizara β_0, reemplazando P por la matriz identidad?

Pauta.

1. Por diferenciación,

$$\boxed{\nabla F(\beta) = \frac{1}{n}X^\top(X\beta - y) + \lambda P\beta, \qquad \nabla^2 F(\beta) = \frac{1}{n}X^\top X + \lambda P.}$$

Todo minimizador satisface las ecuaciones normales

$$(X^\top X + n\lambda P)\widehat{\beta} = X^\top y.$$

2. Para $v = (v_0, \ldots, v_p)^\top \neq 0$,

$$v^\top(X^\top X + n\lambda P)v = \|Xv\|_2^2 + n\lambda\sum_{j=1}^p v_j^2.$$

Si algún $v_j \neq 0$ con $j \geq 1$, el segundo término es positivo. En caso contrario, $v_0 \neq 0$ y $Xv = v_0\mathbf{1}_n$, por lo que el primer término es $nv_0^2 > 0$. Así, la matriz es definida positiva e invertible, y

$$\boxed{\widehat{\beta} = (X^\top X + n\lambda P)^{-1}X^\top y.}$$

Este punto existe y es estacionario. Como F es dos veces continuamente diferenciable en el conjunto abierto y convexo $\mathbb{R}^{p+1}$ y su Hessiana es definida positiva, F es estrictamente convexa y $\widehat{\beta}$ es su único minimizador global.

3. La ecuación correspondiente al intercepto es

$$n\widehat{\beta}_0 + \sum_{j=1}^{p} \widehat{\beta}_j \sum_{i=1}^{n} X_{ij} = \sum_{i=1}^{n} y_i.$$

Al estar centrados los predictores, las sumas interiores son cero y

$$\boxed{\widehat{\beta}_0 = \bar{y}.}$$

Si también se penaliza el intercepto, su ecuación pasa a ser $n(1+\lambda)\widehat{\beta}_0 = n\bar{y}$, de modo que

$$\boxed{\widehat{\beta}_0 = \frac{\bar{y}}{1+\lambda}.}$$

Anexo: resultados útiles

Puede utilizar los siguientes resultados sin demostrarlos. En cada aplicación, verifique las hipótesis correspondientes.

1. Matrices definidas positivas y negativas

Una matriz simétrica $A \in \mathbb{R}^{d\times d}$ es:

- **Semidefinida positiva** si $v^\top Av \geq 0$ para todo $v \in \mathbb{R}^d$.
- **Definida positiva** si $v^\top Av > 0$ para todo $v \neq 0$.
- **Definida negativa** si $v^\top Av < 0$ para todo $v \neq 0$.

Toda matriz definida positiva o definida negativa es invertible.

2. Condiciones de optimalidad y convexidad

Sea $f : U \to \mathbb{R}$ dos veces continuamente diferenciable, donde $U \subseteq \mathbb{R}^d$ es abierto.

- Si $x^* \in U$ es un mínimo o máximo local, entonces $\nabla f(x^*) = 0$.
- Si $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*)$ es definida positiva, entonces x^* es un mínimo local estricto. Si es definida negativa, es un máximo local estricto.
- Si, además, U es convexo y $\nabla^2 f(x)$ es semidefinida positiva para todo $x \in U$, entonces f es convexa. Si la Hessiana es definida positiva en todo U, entonces f es estrictamente convexa.
- Para una función convexa diferenciable, todo punto estacionario es un minimizador global. La convexidad estricta garantiza que hay a lo más un minimizador, pero por sí sola no garantiza su existencia.

3. Lema de descenso

Sea $f : \mathbb{R}^d \to \mathbb{R}$ una función diferenciable cuyo gradiente es Lipschitz con constante $L > 0$, es decir,

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2 \qquad \text{para todo } x, y \in \mathbb{R}^d.$$

Entonces, para todo $x, y \in \mathbb{R}^d$,

$$\boxed{f(x) \leq f(y) + \langle \nabla f(y), x - y\rangle + \frac{L}{2}\|x - y\|_2^2.}$$

En dimensión uno, el gradiente es la derivada, el producto interno es el producto usual y la norma es el valor absoluto.