

Prueba 1

Instrucciones

Problema 1. Sea $X_1, \dots, X_n$ una muestra aleatoria independiente proveniente de una distribución

$$X_i \sim N(\mu, \sigma^2),$$

donde tanto μ como σ^2 son desconocidos.

1. Calcule el gradiente de la log-verosimilitud con respecto a los parámetros (μ, σ^2) .
2. Calcule la matriz Hessiana de la log-verosimilitud.
3. Encuentre los estimadores de máxima verosimilitud de μ y σ^2 .
4. Utilice la matriz Hessiana para verificar que el punto obtenido corresponde a un máximo.

Problema 2. Sea $f(t) = at^2/2$, con $a > 0$. Considere el método de descenso de gradiente con paso constante $\gamma > 0$, iniciado en $t_0 \neq 0$:

$$t_{k+1} = t_k - \gamma f'(t_k), \quad k = 0, 1, \dots$$

1. Encuentre el único minimizador global de f y obtenga una expresión explícita para t_k en términos de t_0 , a y γ .
2. Determine todos los valores de $\gamma > 0$ para los cuales t_k converge al minimizador. Describa qué ocurre cuando $\gamma = 1/a$ y cuando $\gamma = 2/a$.
3. Aplique el lema de descenso del anexo con $L = a$ para demostrar que

$$f(t_{k+1}) \leq f(t_k) - \gamma \left(1 - \frac{a\gamma}{2}\right) |f'(t_k)|^2.$$

¿Para qué valores de γ garantiza esta desigualdad un descenso estricto cuando $t_k \neq 0$? Compare con el intervalo de convergencia obtenido anteriormente.

4. Escriba la actualización del método de Newton con paso completo y demuestre que alcanza el minimizador en una iteración desde cualquier punto inicial. ¿A qué elección de γ corresponde en este ejemplo?

Problema 3. Sea $X \in \mathbb{R}^{n \times (p+1)}$, con $n \geq 1$, una matriz cuya primera columna está formada por unos. Las demás columnas pueden ser linealmente dependientes. Para $y \in \mathbb{R}^n$, $\lambda > 0$ y $P = \text{diag}(0, 1, \dots, 1)$, considere el objetivo de regresión Ridge

$$F(\beta) = \frac{1}{2n} \|y - X\beta\|_2^2 + \frac{\lambda}{2} \beta^\top P \beta, \quad \beta = (\beta_0, \beta_1, \dots, \beta_p)^\top.$$

El intercepto β_0 no se penaliza.

1. Calcule el gradiente y la matriz Hessiana de F . Deduzca las ecuaciones que debe satisfacer un minimizador.

2. Demuestre que

$$v^\top (X^\top X + n\lambda P)v > 0 \quad \text{para todo } v \in \mathbb{R}^{p+1} \setminus \{0\}.$$

Concluya que existe un único minimizador global, incluso si las columnas de X son linealmente dependientes, y encuentre una expresión para él.

3. Suponga que cada columna de predictores está centrada, es decir, $\sum_{i=1}^n X_{ij} = 0$ para $j = 1, \dots, p$. Demuestre que el intercepto estimado es $\hat{\beta}_0 = \bar{y}$, donde $\bar{y} = n^{-1} \sum_{i=1}^n y_i$. ¿Cuál sería el intercepto estimado si también se penalizara β_0 , reemplazando P por la matriz identidad?

Anexo: resultados útiles

Puede utilizar los siguientes resultados sin demostrarlos. En cada aplicación, verifique las hipótesis correspondientes.

1. Matrices definidas positivas y negativas

Una matriz simétrica $A \in \mathbb{R}^{d \times d}$ es:

- **Semidefinida positiva** si $v^\top Av \geq 0$ para todo $v \in \mathbb{R}^d$.
- **Definida positiva** si $v^\top Av > 0$ para todo $v \neq 0$.
- **Definida negativa** si $v^\top Av < 0$ para todo $v \neq 0$.

Toda matriz definida positiva o definida negativa es invertible.

2. Condiciones de optimalidad y convexidad

Sea $f : U \rightarrow \mathbb{R}$ dos veces continuamente diferenciable, donde $U \subseteq \mathbb{R}^d$ es abierto.

- Si $x^* \in U$ es un mínimo o máximo local, entonces $\nabla f(x^*) = 0$.
- Si $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*)$ es definida positiva, entonces x^* es un mínimo local estricto. Si es definida negativa, es un máximo local estricto.
- Si, además, U es convexo y $\nabla^2 f(x)$ es semidefinida positiva para todo $x \in U$, entonces f es convexa. Si la Hessiana es definida positiva en todo U , entonces f es estrictamente convexa.
- Para una función convexa diferenciable, todo punto estacionario es un minimizador global. La convexidad estricta garantiza que hay a lo más un minimizador, pero por sí sola no garantiza su existencia.

3. Lema de descenso

Sea $f : \mathbb{R}^d \rightarrow \mathbb{R}$ una función diferenciable cuyo gradiente es Lipschitz con constante $L > 0$, es decir,

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2 \quad \text{para todo } x, y \in \mathbb{R}^d.$$

Entonces, para todo $x, y \in \mathbb{R}^d$,

$$f(x) \leq f(y) + \langle \nabla f(y), x - y \rangle + \frac{L}{2} \|x - y\|_2^2.$$

En dimensión uno, el gradiente es la derivada, el producto interno es el producto usual y la norma es el valor absoluto.