

IECD 401 - Machine Learning

Ejercicios Clases 18 y 19: Redes Neuronales.

Ejercicio 1. Considere la red neuronal

$$f(x) = \sigma \left(\sum_{j=1}^2 a_j \sigma(w_j^\top x + b_j) + c \right),$$

donde $\sigma(t) = \max(0, t)$ corresponde a la llamada función de activación RELU..

Los parámetros de la red son

$$w_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad b_1 = 0,$$

$$w_2 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad b_2 = -1,$$

$$a_1 = 3, \quad a_2 = -2, \quad c = 0.$$

1. Calcule la salida de la red en los puntos

$$x = (0, 0), \quad x = (1, 1), \quad x = (2, -1).$$

2. Determine las ecuaciones de las rectas

$$w_1^\top x + b_1 = 0, \quad w_2^\top x + b_2 = 0.$$

3. Si la regla de clasificación es

$$\hat{y} = \begin{cases} 1 & \text{si } f(x) \geq 1/2, \\ 0 & \text{en otro caso,} \end{cases}$$

describa cualitativamente qué tipo de regiones puede clasificar esta red. Ayúdesé dándose cuenta que $\mathbb{R}^2$ queda particionado en 4 pedacitos, determinados por las dos rectas anteriores.

En cada uno de esos pedacitos usted puede evaluar la capa oculta sin mayores problemas.

Ejercicio 2. Considere una red neuronal con para datos en $\mathbb{R}^d$ y respuesta en $\mathbb{R}$. Calcule el número de parámetros en una red con una capa oculta de m neuronas, y en una red con dos capas ocultas de m_1 y m_2 neuronas respectivamente.

Ejercicio 3. Considere la red neuronal

$$f(x) = a_1 \sigma(w_1 x + b_1) + a_2 \sigma(w_2 x + b_2),$$

donde $x \in \mathbb{R}$ y $\sigma(t) = \frac{1}{1+e^{-t}}$.

Suponga que usted tiene una sola observación (x, y) . Defina la función de pérdida cuadrática

$$L = (y - f(x))^2.$$

1. Calcule

$$\frac{\partial L}{\partial a_1}.$$

2. Calcule

$$\frac{\partial L}{\partial w_1}.$$

3. Explique por qué la función sigmoide puede producir gradientes muy pequeños cuando sus entradas toman valores grandes en magnitud.

Ejercicio 4. Considere el problema de regresión lineal

$$\min_{\beta \in \mathbb{R}^d} \frac{1}{2} \|X\beta - y\|_2^2,$$

donde

$$X \in \mathbb{R}^{n \times p}, \quad y \in \mathbb{R}^n,$$

y suponga que: $d > n$, y $X\beta = y$ tiene solución, por lo tanto el mínimo en el problema de optimización es 0.

Considere gradient descent con inicialización

$$\beta_0 = 0 \in \mathbb{R}^d,$$

y actualización

$$\beta_{k+1} = \beta_k - \eta X^\top (X\beta_k - y) \in \mathbb{R}^d$$

donde $\eta > 0$ es el tamaño del paso.

1. Demuestre que $\beta_k \in \text{Im}(X^\top)$ para todo $k \geq 0$.
2. Muestre que los vectores de $\text{Im}(X^\top)$ son ortogonales a los de $\ker(X)$.
3. Sea β^* una solución cualquiera de $X\beta = y$. Demuestre que toda solución puede escribirse como

$$\beta^* = \beta_{\min} + v,$$

donde $v \in \ker(X)$, y $\beta_{\min} \in \text{Im}(X^\top)$.

4. Muestre que $\beta_{\min}$ en la descomposición anterior es único: para esto suponga que

$$\beta^* = \beta'_{\min} + v',$$

con $\beta'_{\min} \in \text{Im}(X^\top)$, $\beta'_{\min} \neq \beta_{\min}$ y $v' \in \ker(X)$, luego deduzca que $\beta_{\min} - \beta'_{\min} \in \ker(X)$, y encuentre una contradicción.

5. Usando las partes anteriores, explique por qué gradient descent no puede converger a una solución con componente en $\ker(X)$.
6. Concluya que, si gradient descent converge a una solución β_∞ entonces:

$$\|\beta_\infty\|_2 = \arg \min_{\beta: X\beta=y} \|\beta\|_2.$$