Clase 1: Machine learning

9/Mar/26.

$\boxed{\text{Statistical learning.}}$ $\approx$ Machine Learning $\approx$ Estadística

---

Problemas Estadísticos.

- Regresión

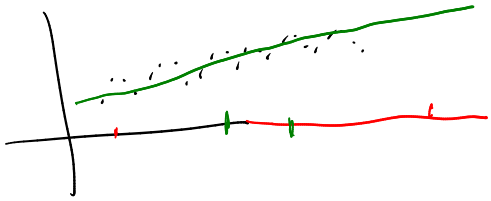

$$y = a_0 + a_1 x + a_2 x^2 + \dots + a_k x^k$$

$$(x_i, y_i) \quad x_i \in \mathbb{R}^d, \; y_i \in \mathbb{R}$$

- Clasificación:

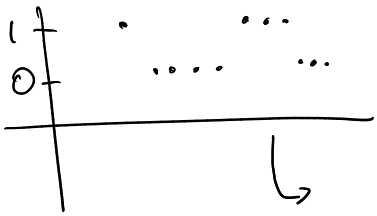

$$(x_i, y_i) \quad x_i \in \mathbb{R}^d, \; y_i \in \{0,1\}$$

$$P(y=1) = \sigma(a_0 + a_1 x + \dots + a_k x^k)$$

$$\sigma(x) = \frac{e^x}{1+e^x}$$

- Clustering: (X_i) No tiene (variable) respuesta

- Testear / Prueba de hipótesis: (X_i) y quero probar que la distribución tiene cierta propiedad

---

Tipos de Problemas: $\rightarrow$ Supervisados
$\rightarrow$ No Supervisados

Supervisado: existe variable de Respuesta (y_i)

No Supervisado: No existe la variable de Respuesta.

2. Nuestro foco: Problema de predicción.

(X_i, y_i) → variable respuesta.

Covariables / ~~features~~ características

Objetivo: construir una función $f: \mathbb{R}^d \to \mathcal{Y}$; $X_i \in \mathbb{R}^d$, $y_i \in \mathcal{Y}$ → $\mathbb{R}$, $\{0,1\}$, $\{1,2,\dots,K\}$

tal que $y_i \approx f(X_i)$ para todo X_i

y $y \approx f(X)$ para los datos No observados.

2.1 Función de Pérdida / Loss functions.

$$L: \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}$$

$\mathcal{Y}$: Respuesta; $\mathcal{Y}$: Predicción.

Ejemplos:

$L(y, \hat{y}) = (y - \hat{y})^2$ pérdida cuadrática / square loss

$L(y, \hat{y}) = |y - \hat{y}|$ pérdida absoluta

$L(y, \hat{y}) = \mathbb{1}_{\{y \neq \hat{y}\}}$ pérdida de clasificación

Importante recordar que $\hat{y} = \hat{f}(x)$

— o —

2.2 Riesgo / Risk

Asumimos que $(X, y) \sim P$ → Podemos definir el Riesgo.

$$R(f) = \mathbb{E}(L(y, f(X)))$$

Nos gustaría resolver:

$$\hat{f} = \underset{f \in \mathcal{F}}{\operatorname{argmin}} \; R(f)$$

↳ Clase de funciones

En regresión Lineal

$\mathcal{F}$ = polinomios de algún grado.

$L(y, \hat{y}) = (y - \hat{y})^2$

2.3 Función de Riesgo empírico.

$$\hat{R}(f) = \frac{1}{n}\sum_{i=1}^{n} L(y_i, f(x_i))$$

y el correspondiente estimador

$$\hat{f} = \underset{f \in \mathcal{F}}{\operatorname{Argmin}} \; \hat{R}(f)$$

Ejemplo: $(x_i, y_i) \in \mathbb{R} \times \mathbb{R}$; $\quad f(x) = a_0 + a_1 x$
(Regresión Lineal)

Mínimos cuadrados $\quad \min_{a_0, a_1} \left\{ \frac{1}{n} \sum_{i=1}^{n} \left(y_i - (a_0 + a_1 x_i)\right)^2 \right\}$

Ejemplo: Maxima Verosimilitud

(x_i, y_i); $\quad y_i \sim N(f(x_i), \sigma^2)$; $\quad f(x_i) = a_0 + a_1 x_i$

$$\text{Likelihood}\left((x_i, y_i)_{i=1}^{n}\right) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - f(x_i))^2}{2\sigma^2}\right)$$

$$\min_{a_0, a_1, \sigma} \left\{ -\text{Likelihood}\left((x_i, y_i)_{i=1}^{n}\right) \right\}$$

equivalente

$$\min_{a_0, a_1, \sigma} \left\{ -\log\left(\text{Likelihood}(\underline{\text{Datos}})\right) \right\}$$

Generalización y Overfitting

$R(f) \leftarrow$ función de riesgo y $\hat{R}(f) \leftarrow$ función de riesgo empírica.

Generalizar: $\quad R(f) \approx \hat{R}(f)$.

Overfitting: Ocurre cuando un modelo / función $\hat{f}$ es muy bueno minimizando $f \to \hat{R}(f)$, pero es muy malo minimizando $f \to R(f)$

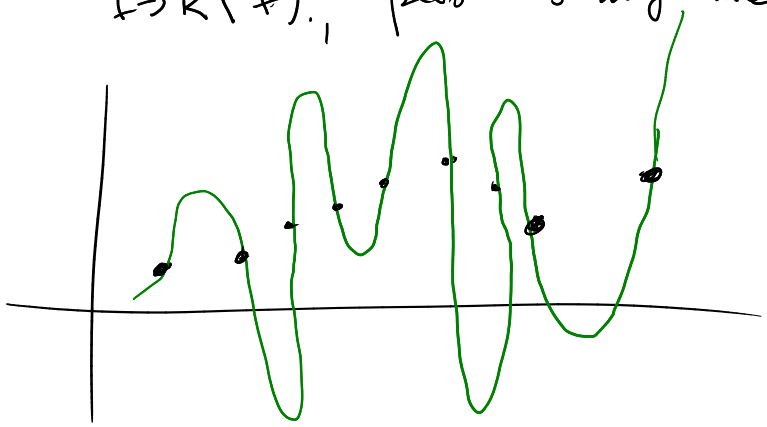

$$P(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_{100} x^{100}$$

Bias - Variance Tradeoff.

$$\mathbb{E}\left((y - \hat{f}(x))^2 \right) = \text{Bias}^2 + \text{Varianza} + \text{Ruido}.$$

Supuesto $\quad y = f(x) + \varepsilon \,;\; \mathbb{E}(\varepsilon) = 0.$

$$\text{Bias} = f(x) - \mathbb{E}(\hat{f}(x))$$

$$\text{Varianza} = \mathbb{E}\left(\left| \hat{f}(x) - \mathbb{E}(\hat{f}(x)) \right|^2 \right) = \text{Var}(\hat{f}(x))$$

$$\text{Ruido} = \text{Var}(\varepsilon)$$