Clase 6: Regularización.

$$\hat{\beta} = \arg\min_{\beta} \underbrace{\frac{1}{n}\sum_{i=1}^{n} \ell(y_i, f_\beta(x_i))}_{\text{Riesgo empírico}}$$

(x_i, y_i) Datos

$x_i \in \mathbb{R}^d$

$y \in \mathbb{R}$ o $\{0,1\}$

Cuando d es grande hay más chances de encontrar correlaciones falsas o espurias.

β_1 altura $+ \beta_2$ peso

$+ \beta_3$ presión $+ \beta_4$ sexo

$+ \beta_5$ altura $\times$ peso

$+ \beta_6 \frac{\text{altura}}{\text{peso}}$

$+ \beta_7 \frac{\text{peso}}{\text{altura}}$

Para evitar lo anterior se usa regularización.

$$\hat{\beta} = \arg\min_{\beta} \left\{ \left(\frac{1}{n}\sum_{i=1}^{n} \ell(y_i, f_\beta(x_i)) \right) + \underbrace{\lambda}_{\lambda \geq 0} \underbrace{\Omega(\beta)}_{\text{función de regularización o penalización}} \right)$$

La idea es que $\Omega(\beta) = \begin{cases} \approx 0 & \text{si } \beta \approx 0 \\ \text{grande} & \text{si } \beta \text{ tiene valores grandes.} \end{cases}$

En la práctica hay dos funciones usadas:

1) $\Omega(\beta) = \|\beta\|_2^2 = \sum_{i=0}^{d} \beta_i^2$ (Ridge)

puede empezar en $i=1$. si no se quiere incorporar el intercepto.

2) $\Omega(\beta) = \|\beta\|_1 = \sum_{i=1}^{d} |\beta_i|$ (Lasso)

y se pueden combinar

3) $\Omega(\beta) = \alpha_1 \|\beta\|_1 + \alpha_2 \|\beta\|_2^2$ (Elastic Net)

También existe

4) $\Omega(\beta) = \|\beta\|_0 = \#\{i : \beta_i \neq 0\}$

$= \#$ coeficientes distintos de 0.