Clase 7: Regularización II.

Ejemplo: Regresión Ridge.

Datos

$$X = \begin{pmatrix} - x_1 - \\ - x_2 - \\ \vdots \\ - x_n - \end{pmatrix}, \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

$$x_i \in \mathbb{R}^{d+1} \qquad y_i \in \mathbb{R}$$

En regresión el Riego empírico está dado por

$$\hat{R}(\beta) = \frac{1}{n}(y - X\beta)^T (y - X\beta)$$

entonces en regresión ridge queremos minimizar.

$$Q(\beta) = \frac{1}{n}(y - X\beta)^T (y - X\beta) + \lambda \sum_{i=0}^{d} \beta_i^2 \; ; \quad \lambda \geq 0$$

elegido por nosotros.

entonces $(\nabla_\beta Q)(\beta) = -\frac{2}{n} X^T (y - X\beta) + 2\lambda \beta$

Así resolvemos: $(\nabla_\beta Q)(\beta) = 0$

$$\Rightarrow -\frac{1}{n} X^T y + \underline{\frac{1}{n} X^T X \beta + \lambda \beta} = 0.$$

$$\Rightarrow \left(\frac{1}{n} \underset{(d+1)\times n}{X^T} \underset{n \times (d+1)}{X} + \lambda \underset{(d+1)\times(d+1)}{I} \right) \underset{(d+1)\times 1}{\beta} = \underbrace{\frac{1}{n} \underset{(d+1)\times n}{X^T} \underset{n\times 1}{y}}_{(d+1)\times 1}$$

Asumiendo inversa $\Rightarrow$

$$\beta = \left(\frac{1}{n} X^T X + \lambda I \right)^{-1} \cdot \frac{1}{n} X^T y.$$

2) Regresión Lasso.

mismo contexto de regresión lineal.

modelo

$$\boxed{y = X\beta + \varepsilon}$$

en estadística la gente llama al error.

Datos

$$X = \begin{pmatrix} - & x_1 & - \\ - & x_2 & - \\ & \vdots & \\ - & x_n & - \end{pmatrix}$$

$x_i \in \mathbb{R}^{d+1}$

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}; \quad y_i \in \mathbb{R}$$

y lo que queremos minimizar es:

$$Q(\beta) = \frac{1}{n}(y - X\beta)^T(y - X\beta) + \lambda \sum_{i=0}^{d} |\beta_i| \; ; \; \lambda \geq 0 \text{ elegido por el usuario.}$$

Vamos a ver después como minimizar esto.

Por ahora tratemos de entender qué estamos minimizando.

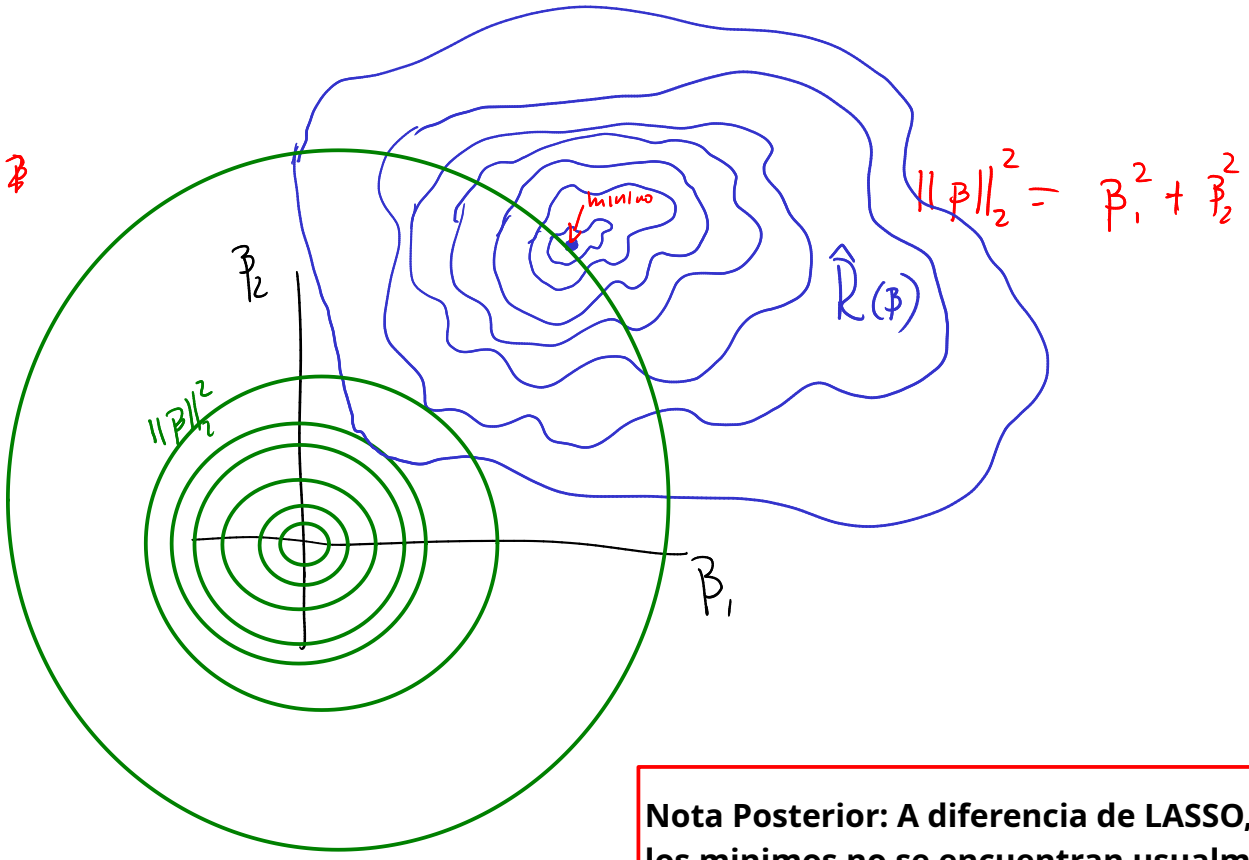

Nota Posterior: A diferencia de LASSO, en RIDGE los minimos no se encuentran usualmente en los ejes, por lo que es más difícil obtener entradas del vector beta iguales a 0.

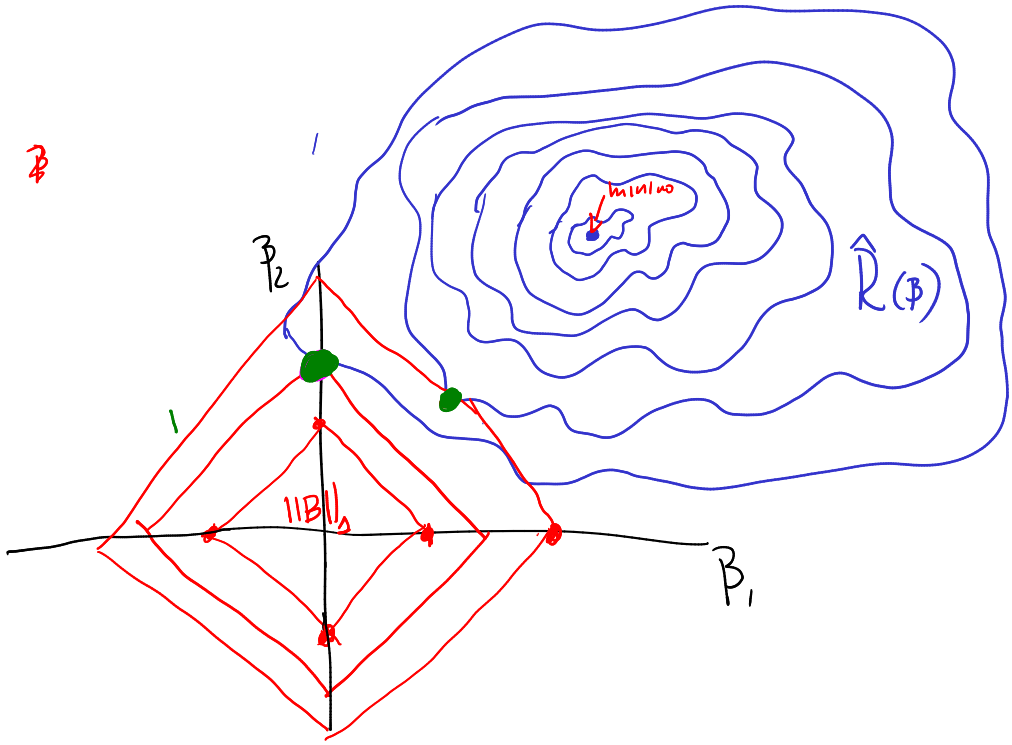

$\|\beta\|_1 = |\beta_1| + |\beta_2| = 1$

$\|\beta\|_1 = 1$

Nota posterior: En general, en la práctica es común que las soluciones óptimas se encuentren en las puntas. Lo que significa que algunas entradas del vector de betas serán 0, lo que significa que son ignoradas por el modelo.