Clase 8. Regularización III

30/03/26.

Ridge: $\hat{R}(\beta) + \lambda \|\beta\|_2^2$ $\quad \sum_{i=1}^{d} \beta_i^2$

Lasso: $\hat{R}(\beta) + \lambda \|\beta\|_1$ $\quad \sum_{i=1}^{d} |\beta_i|$

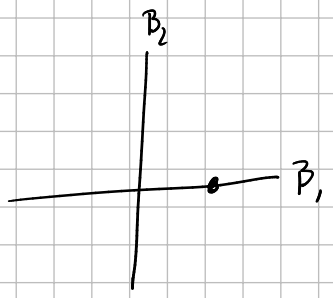

1) Un poco de optimización y Convexidad

Definición: Convexidad

Sea $f: \mathbb{R}^d \to \mathbb{R}$. Decimos que f es convexa si

$$f(\theta\beta + (1-\theta)\beta') \leq \theta f(\beta) + (1-\theta) f(\beta')$$

para todo $\theta \in (0,1)$ y todo $\beta, \beta' \in \mathbb{R}^d$

En forma de dibujo

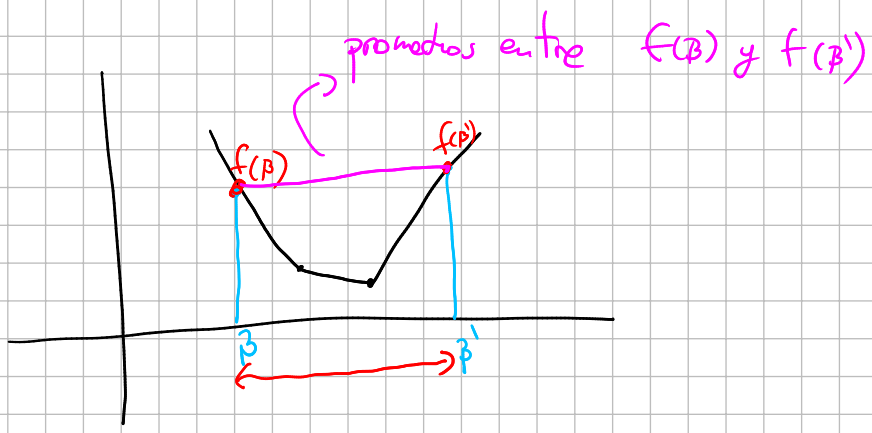

Decimos que f es estrictamente convexa si cambiamos $\leq$ por $<$ en la definición

Proposición: Si f es estrictamente convexa entonces f tiene un único punto donde se minimiza.

Demostración: Sea β y $\beta' \in \mathbb{R}^d$ tales que $f(\beta)$ y $f(\beta')$ son mínimos.

Por definición para $\theta = 1/2$ se tiene

$$f((\beta+\beta')/2) < (f(\beta) + f(\beta'))/2 = \text{mínimo}$$

y esto es una contradicción, luego <u>NO</u> puede haber dos puntos β y β' que minimizen f. $\square$

1.1 Cómo sabemos que una función es convexa?

i) Verificar la definición $\qquad |x+y| \leq |x| + |y|$

ejercicio: $\boxed{f(\beta) = \|\beta\|_1 = \sum_{i=1}^{d} |\beta_i|}$ es convexa.

ii) Si f y g son convexas entonces $f+g$ es convexa.

iii) Criterio de la segunda derivada.

Sea $f: \mathbb{R}^d \to \mathbb{R}$ con segunda derivada.

Entonces si $\underbrace{(Hf)(\beta)}_{\text{matriz } d\times d}$ es definida positiva para todo β

entonces f es estrictamente convexa

Recordemos M es definida positiva si

i) M es simetrica

ii) $x^T M x > 0$ para todo $x \neq 0$, $x \in \mathbb{R}^d$.

<u>Ejemplo del criterio iii</u>

$$L(\beta) = \frac{1}{n}(y - X\beta)^T(y - X\beta) + \lambda\|\beta\|_2^2$$

$$\nabla L(\beta) = -\frac{2}{n} X^T(y - X\beta) + 2\lambda\beta$$

$$(HL)(\beta) = \frac{2}{n} X^T X + 2\lambda I \quad \leftarrow \text{ejercicio}$$

$$\hookrightarrow x^T \underbrace{\left(\frac{2}{n} X^T X + 2\lambda I\right)}_{d\times d} x = \frac{2}{n}(x^T X^T)(Xx) + 2\lambda x^T x$$

$$= \underbrace{\frac{2}{n} \underbrace{(Xx)^T}_{\geq 0} \underbrace{(Xx)}_{\geq 0} + 2\lambda \underbrace{x^T x}_{\sum x_i^2 \geq 0}}_{> 0.}$$

1.2) Cómo encontramos los mínimos?

Sea $f: \mathbb{R}^d \to \mathbb{R}$

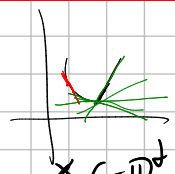

Se define el <u>subgradiente / subdiferencial</u> en $x \in \mathbb{R}^d$ como

$$\partial f(x) = \{ g \in \mathbb{R}^d : f(y) \geq f(x) + g^T (y-x), \ \forall y \in \mathbb{R}^d \}$$

i) Si f es diferenciable en x entonces $\partial f(x) = \{\nabla f(x)\}$

ii) Si f NO es diferenciable entonces $\partial f(x)$ puede ser un conjunto con más de un elemento.

Ejemplo. $f: \mathbb{R} \to \mathbb{R}$ dada por $f(x) = |x|$

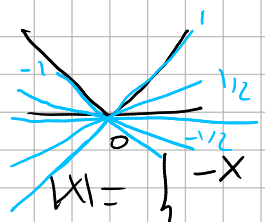

$$|x| = \begin{cases} -x & x<0 \\ x & x>0 \\ 0 & x=0 \end{cases}$$

$$\partial f(x) = \begin{cases} \{-1\} & x<0 \\ \{1\} & x>0 \\ [-1, 1] & x=0 \end{cases}$$

<u>Proposición</u>: Sea $f: \mathbb{R}^d \to \mathbb{R}$ convexa. y sea β^* el minimizador entonces $0 \in \partial f(\beta^*)$.

y si $0 \in \partial f(\beta^*)$ entonces β^* es un minimizador de f.

Ejercicio. encuentre el minimizador de

$$f_1(x) : |x| + |x-1|$$

y

$$f_2(x) : |x-2| + x^2$$

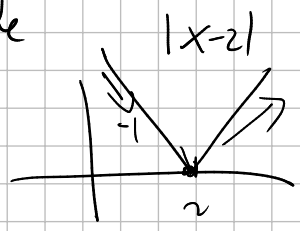

Hagamos el segundo. f_2 es convexa

$$\partial f_2(x) = \partial|x-2| + \underbrace{\partial x^2}_{\{2x\}}$$

y

$$\partial|x-2| = \begin{cases} -1 & x<2 \\ 1 & x>2 \\ [-1,1] & x=2 \end{cases}$$

$x = 1/2$

entonces

$$\partial|x-2| + \partial x^2 = \begin{cases} -1+2x & ; \ x<2 \\ 1+2x & ; \ x>2 \\ [3,5] & ; \ x=2 \end{cases}$$

$\leftarrow$ $\cancel{x=-1/2}$

Luego en $x = 1/2$ se tiene el mínimo valor.

$$f_2(1/2) = \left|\frac{1}{2}-2\right| + \left(\frac{1}{2}\right)^2 = \frac{3}{2} + \frac{1}{4} = \frac{7}{4} = 1.75$$

— o —

Propiedades

i) $f : \mathbb{R}^d \to \mathbb{R}$, $g : \mathbb{R}^d \to \mathbb{R}$.

Suma de Minskowski.

$$\partial(f+g)(x) = \left\{ g_1 + g_2 : \begin{array}{l} g_1 \in (\partial f)(x) \\ g_2 \in (\partial g)(x) \end{array} \right\}$$

ii) Consideremos $x \in \mathbb{R}^d$, $x = \begin{pmatrix} x_1 \\ \vdots \\ x_d \end{pmatrix}$.

Consideremos funciones reales $\mathbb{R} \to \mathbb{R}$, f_i y definimos

$$f(x) = \sum_{i=1}^{d} f_i(x_i)$$

entonces

$$(\partial f)(x) = \left\{ (g_1, g_2, \dots, g_d) \text{ donde } g_i \in (\partial f_i)(x_i) \right\}$$

Ejemplo $f(\beta) = |\beta_1| + |\beta_2|$

$$(\partial f)(0,0) = \left\{ (g_1, g_2) \quad \text{tq} \quad \begin{array}{l} g_1 \in [-1,1] \\ \text{y } g_2 \in [-1,1] \end{array} \right\}$$

$$(\partial f)(1,0) = \{ (1, g) \quad \text{tq} \quad g \in [-1,1] \}$$

$$(\partial f)(1,1) = \{ (1,1) \}$$

---

2. Volvamos a Lasso. (Regresión Lasso)

$$L(\beta) = \frac{1}{n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$$

$$= \frac{1}{n} (y - X\beta)^T (y - X\beta) + \lambda \sum_{i=1}^{d} |\beta_i|$$

Así

$$\partial\left(\frac{1}{n} (y - X\beta)^T (y - X\beta) \right) = \left\{ -\frac{2}{n} X^T (y - X\beta) \right\}$$

y $$\partial\left(\lambda \sum_{i=1}^{d} |\beta_i| \right) = \lambda \underbrace{\begin{pmatrix} z_1 \\ \vdots \\ z_d \end{pmatrix}}_{z} \quad \text{donde } z_i \in \partial|\beta_i|$$

$$\partial L(\beta) = -\frac{2}{n} X^T (y - X\beta) + \lambda z \; ; \quad \text{donde } z \in \partial\|\beta\|_1$$

$$\Rightarrow \partial L(\beta) \ni \vec{0} \iff -\frac{2}{n} X^T (y - X\beta) + \lambda z \ni \vec{0}$$

3) Cómo optimizamos numéricamente Lasso?

3.1 Subgradient Descent

β^0 elegido por el usuario

$$\beta^{(t+1)} = \beta^{(t)} - \eta \cdot g^{(t)} \quad \text{donde} \quad g^{(t)} \in \partial L(\beta^{(t)})$$

3.2) Coordinate Descent. - Descenso por coordenadas.

$$X_{-j} = \begin{array}{c} \text{eliminar columna } j \\ \begin{pmatrix} - & x_1 & - \\ - & x_2 & - \\ & \vdots & \\ - & x_n & - \end{pmatrix} \end{array} \ominus$$

$$r_{-j} = y - X_{-j}\beta_{-j}$$

y así

$$y - X\beta = r_{-j} - X_{\cdot j}\beta_j$$

La función a minimizar es

$$L(\beta) = \frac{1}{n}\|y - X\beta\|_2^2 + \lambda\|\beta\|_1$$

La idea es asumir que ya tenemos los β_i correctos excepto el β_j

$$L(\beta_j) = \underbrace{\frac{1}{n}\|r_{-j} - X_{\cdot j}\beta_j\|_2^2}_{} + \lambda\sum_{i=1}^{d}|\beta_i|$$

$$= \underbrace{\frac{1}{n}\left(\|r_{-j}\|_2^2}_{\text{No depende de } \beta_j} - 2\beta_j r_{-j}^T X_{\cdot j} + \beta_j^2\|X_{\cdot j}\|_2^2\right) + \lambda|\beta_j| + C$$

No depend

$$\partial L(\beta_j) = \underbrace{-\frac{2}{n} r_{-j}^T X_{\cdot j}}_{a_j} + \underbrace{\frac{2}{n}\|X_{\cdot j}\|_2^2}_{b_j}\beta_j + \lambda\,\partial|\beta_j|$$

$$= a_j + b_j\beta_j + \lambda\,\partial|\beta_j|$$

Así

$$\partial L(\beta_j) = \begin{cases} a_j + b_j \beta_j + \lambda & \text{si } \beta_j > 0 \\ a_j + b_j \beta_j - \lambda & \text{si } \beta_j < 0 \\ a_j + b_j \beta_j + \lambda[-1,1] & \text{si } \beta_j = 0 \end{cases}$$

$$= \begin{cases} a_j + b_j \beta_j + \lambda & \text{si } \beta_j > 0 \\ a_j + b_j \beta_j - \lambda & \text{si } \beta_j < 0 \\ [a_j - \lambda \ , \ a_j + \lambda] & \text{si } \beta_j = 0 \end{cases}$$

Resolvemos $0 \in \partial L(\beta_j)$

ojo $\lambda > 0$
$b_j > 0$

i) $\beta_j > 0$; $\beta_j = \dfrac{-\lambda - a_j}{b_j} = -\dfrac{(a_j + \lambda)}{b_j}$

ii) $\beta_j < 0$; $\beta_j = \dfrac{\lambda - a_j}{b_j}$

iii) $\beta_j = 0 \Rightarrow 0 \in [a_j - \lambda, a_j + \lambda]$

Así resuelvo β_j // (podemos escribir una formula cerrada)

Postclase: Podemos definir $S(a, \lambda) = \text{sign}(a)(|a| - \lambda)_+$ que se llama la función "soft-threshold"
Donde la noitación $(y)_+ = \max(y, 0)$

Y entonces tenemos que $\beta_j = \dfrac{S(-a_j, \lambda)}{b_j}$

—o—

Entonces el algoritmo consiste en iterar constantemente
$(\beta_1, \beta_2, \ldots, \beta_d, \beta_1, \beta_2, \ldots \beta_d, \ldots)$