Unidad 3: Modelos No Lineales (Clase 11) 6/Abril/2026.

Objetivo: extender el modelo

$$Y = \beta_0 + \sum_{j=1}^{d} \beta_j X_j \qquad X \in \mathbb{R}^d, \quad \beta_j \in \mathbb{R}$$

a relaciones no-lineales.

1. Modelos Basados en Expansión de bases / Basis Expansion Models

Y = respuesta $\in \mathbb{R}$ y queremos modelar $Y = f(X)$

X = vectores en $\mathbb{R}^d$

La idea es considerar un modelo de la forma

$$Y = \beta_0 + \sum_{m=1}^{M} \beta_m h_m(X)$$

donde $h_m : \mathbb{R}^d \to \mathbb{R}$ son funciones.

El ejemplo canónico es cuando $d = 1$, y elegimos $h_m(x) = x^m$.

$$\boxed{Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_M x^M}$$ Base polinomial

Entonces con datos $(\underset{\in \mathbb{R}}{x_i}, \underset{\in \mathbb{R}}{y_i})$ hacemos

$$H = \begin{bmatrix} 1 & x_1 & x_1^2 & x_1^3 & \cdots & x_1^M \\ 1 & x_2 & x_2^2 & x_2^3 & & x_2^M \\ \vdots & & & & & \\ 1 & x_n & x_n^2 & x_n^3 & \cdots & x_n^M \end{bmatrix}$$

matricialmente $\underset{\text{vector}}{Y} = H\beta$

y $\hat{\beta} = (H^T H)^{-1} H^T Y$

Ejemplo: Funciones Radiales.

$$y = \beta_0 + \beta_1 h_1(x) + \beta_2 h_2(x) + \cdots + \beta_M h_M(x)$$

$x \in \mathbb{R}^d$.

Elegimos $h_m(x) = \exp\left(-\gamma \overbrace{\|x - \mu_m\|_2^2}^{\text{Radio}}\right)$

γ es un parámetro positivo.

μ_m es un vector en $\mathbb{R}^d$

y $\|z\|_2^2 = \sum_{i=1}^{d} z_i^2$

Importante: γ y los vectores μ_m son elegidos por el usuario.

con datos $(\underset{\mathbb{R}^d}{x_1}, \underset{\mathbb{R}}{y_1}), (x_2, y_2), \ldots, (x_n, y_n)$

$$H = \begin{bmatrix} 1 & h_1(x_1) & h_2(x_1) & \cdots & h_M(x_1) \\ 1 & h_1(x_2) & h_2(x_2) & & h_M(x_2) \\ 1 & h_1(x_3) & h_2(x_3) & & h_M(x_3) \\ \vdots & & & & \\ 1 & h_1(x_n) & h_2(x_n) & \cdots & h_M(x_n) \end{bmatrix}$$

$\to$

Splines: $x \in \mathbb{R}$, $y \in \mathbb{R}$

Consideremos las funciones $1, x, x^2, x^3$

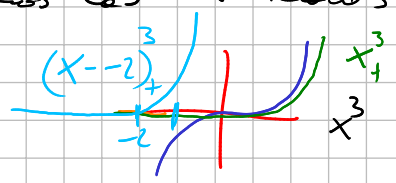

$(x-\xi_1)_+^3, (x-\xi_2)_+^3, \ldots, (x-\xi_M)_+^3$

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x-\xi_1)_+^3 + \beta_5 (x-\xi_2)_+^3 + \cdots + \beta_{M+3} (x-\xi_M)_+^3$$

nudos / knots.

En general, este tipo de modelos tiende a hacer overfitting. Podemos regularizar de la forma tradicional, pero hay alternativas.

Por ejemplo cuando $x \in \mathbb{R}$ podemos regularizar de la siguiente forma.

$$y = \overbrace{\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x-\xi_1)_+^3 + \beta_5 (x-\xi_2)_+^3 + \cdots + \beta_{m+3} (x-\xi_m)_+^3}^{f_\beta(x)}$$

nudos / knots.

Con datos tenemos que minimizar la perdida

$$\hat{R}(\beta) = \frac{1}{n} \sum_{i=1}^{n} (y_i - f_\beta(x_i))^2$$

$$\frac{\partial^2}{\partial x^2}(1+x) = 0$$

$$\frac{\partial^2}{\partial x^2} 1 + x - x^2 = -2$$

y regularizamos:

$$Q(\beta) = \frac{1}{n} \sum_{i=1}^{n} (y_i - f_\beta(x_i))^2 + \lambda \int f_\beta^{(2)}(t)^2 \, dt$$

Rango de los datos x.

$$\lambda \frac{1}{n} \sum_{i=1}^{n} f^{(2)}(x_i)$$

Nota post-clase: aproximar así la integral, no se recomienda mucho, en general se prefiere usar una función f simple y calcular la integral usando el rango de los datos como límites de integración.