(No entran pruebas)

Clase 13: Modelos No-Lineales III.

13/4/1/2026

Árboles de decisión y Random Forest

Datos: $(x_i, y_i)_{i=1}^{n}$, $x_i \in \mathbb{R}^d$

$y_i \to \mathbb{R}$ en regresión

$y_i \to \{1, 2, \dots, K\}$ en clasificación.

Idea

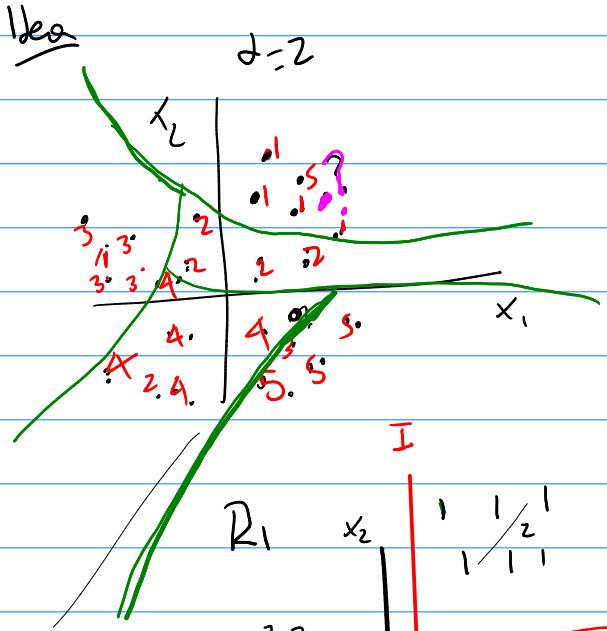

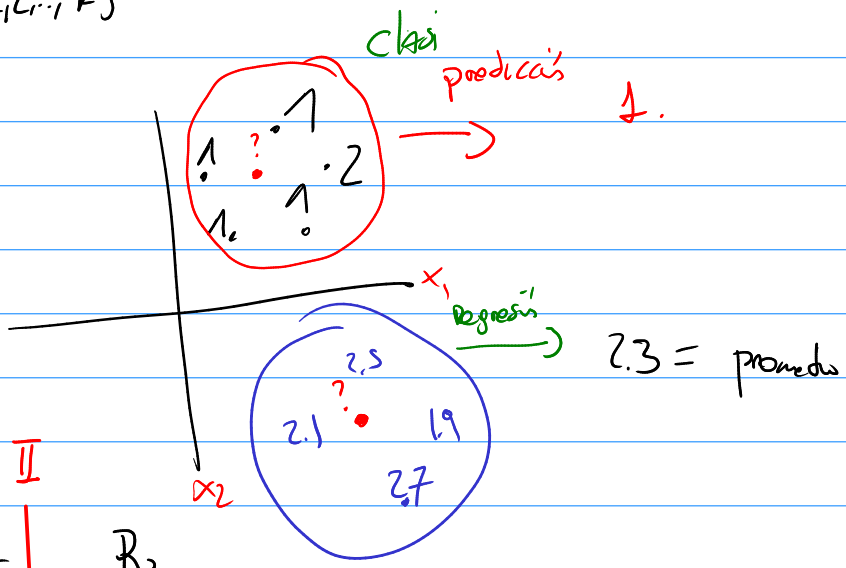

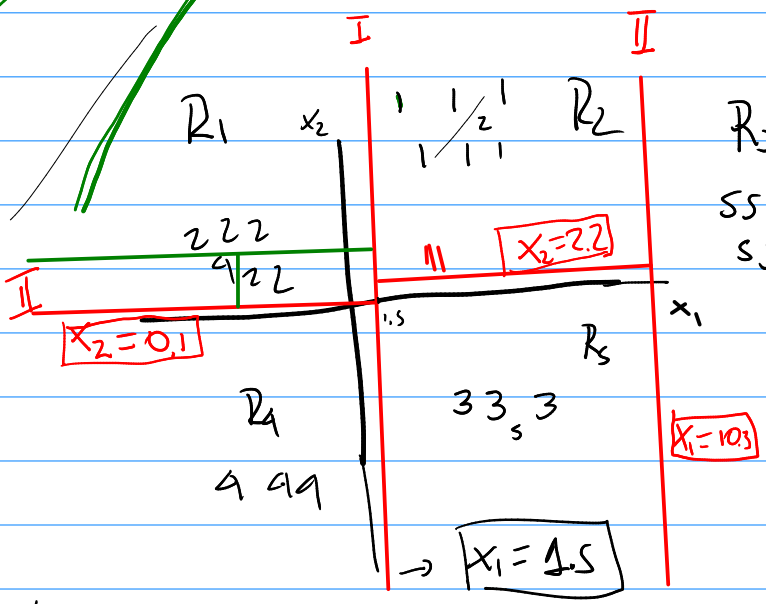

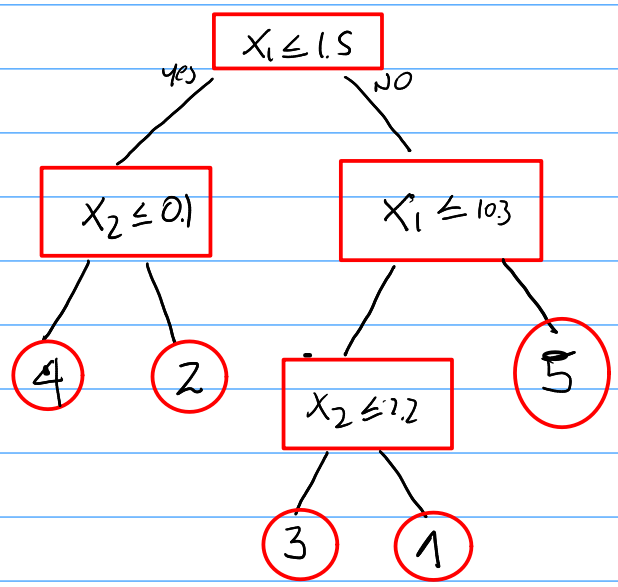

Este es el dibujo en muchas dimensiones.

¿Cuál es el problema?

$$y_i = \beta_0 + \beta_1 x_i$$

$$\beta_0 = \bar{x} - \beta_1 \bar{y}$$

$$\beta_1 = \frac{S_{xy}}{S_y^2}$$

$$S_{xy} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{n}$$

$$S_y = \sum_{i=1}^{n} (y_i - \bar{y})^2 / n$$

¿Cómo se estima un árbol de decisión?

Un árbol es una partición de $\mathbb{R}^d$ en M regiones.

es decir las regiones $R_1, R_2, \dots, R_M$ son disjuntas y

$$R_1 \cup R_2 \dots \cup R_M = \mathbb{R}^d$$

y el predictor

$$\boxed{f(x) = \underbrace{\sum_{i=1}^{M} c_m \mathbb{1}(x \in R_m)}_{\text{retornamos el valor } c_m \text{ si las covariables } x \text{ pertenecen a } R_m}}$$

en general

$$c_m = \begin{cases} \text{Promedio de los } y_i \text{ en } x_i \in R_m & ; \text{ Regresión} \\ \text{la moda de los } y_i \text{ en } x_i \in R_m & \text{clasificación} \end{cases}$$

En árboles de decisión solo consideramos regiones que vienen de hacer consultas del tipo $Q_i = \{ x_k \leq v \}$ ← esto es lo que llamamos un split

algún valor

alguna covariable

C/ consulta tiene asociado un conjunto.

$$A_i = \{ x \in \mathbb{R}^d \text{ tal que la consulta } Q_i \text{ responde sí} \}$$

y las regiones son intersecciones de los A_i o A_i^c

¿Qué queremos minimizar?

<u>Regresión:</u> $\min_{f \in \mathcal{F}} \sum_{i=1}^{n} (y_i - f(x_i))^2 = \sum_{m=1}^{M} \sum_{\substack{i: \\ x_i \in R_m}} (y_i - c_m)^2$

función definida por splits.

todos los árboles de decisión posibles.

<u>clasificación:</u> es un poco más complicado.

en el clase k definimos. $P_{mk} = \frac{1}{N_m} \sum_{i=1}^{n} \mathbb{1}_{\{y_i = k, x_i \in R_m\}}$

con $N_m = \#\{x_i \text{ en } R_m\}$

P_{mk} = la probabilidad de tomar un punto en clase k.
si elegimos un dato al AZAR en la región M.

Definimos

#clases

$$G(R_m) = 1 - \sum_{k=1}^{K} P_{mk}^2 ;$$

← 0 si la región es pura

← 1 si la región es más heterogenea

y la función de Riesgo es $\sum_{m=1}^{M} G(R_m)$

— · —

En general queremos Regularizar la función de pérdida / Riesgo.

$$\min_{T} \{ \hat{R}(T) + \lambda |T| \}$$

tree

>0

1. Tamaño del árbol
2. # de hojas ← más común

Resolver el problema de optimización es <u>MUY</u> difícil en la práctica, así que aproximamos una solución.

Usamos una aproximación local. Dada una región R

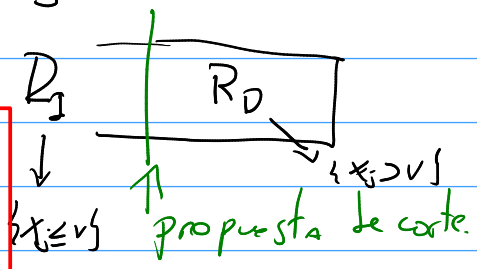

$$\boxed{\mathcal{L}(R_I, R_D) = \begin{cases} \underbrace{\sum_{i: x_i \in R_I} (y_i - \bar{y}_I)^2 + \sum_{i: x_i \in R_D} (y_i - \bar{y}_D)^2}_{\text{Regresión}} \\ \underbrace{N_I\, G(R_I) + N_D\, G(R_D)}_{\text{clasificación}} \end{cases}}$$

N_I, N_D: # elementos en R_I, R_D

Encontrar un corte óptimo de acuerdo a $\mathcal{L}$ <u>NO</u> es difícil.

Sea $R_I(j,s) = \{x \in R;\ x_j \le s\}$; $j \leftarrow$ covariable a elegir (peso, edad, ..)

$R_D(j,s) = \{x \in R:\ x_j > s\}$ $s \leftarrow$ corte 30 kg, 150 cm

Entonces buscamos j^* y s^* tq minimiza

$$\min_{\substack{j \in \{1,\dots,d\} \\ s \in \mathbb{R}}} \mathcal{L}(R_I(j,s), R_D(j,s))$$

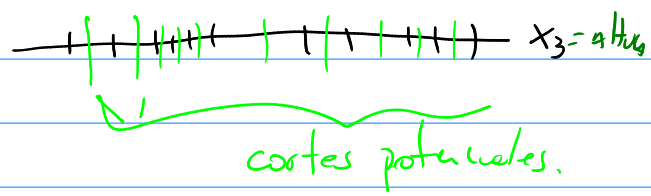

Algoritmo CART

1) $R \leftarrow \mathbb{R}^d$

2) Si R cumple la condición de parada $\left(\begin{array}{l} 1.\ R \text{ es puro} \\ 2.\ \#\text{elementos en } R \text{ es chico} \end{array}\right)$

3) i) buscamos (j^*, s^*) q' minimizan $(j,s) \to \delta(R_I(j,s), R_D(j,s))$

índice de var — un valor en $\mathbb{R}$

ii) particionamos R en $R_I(j^*,s^*)$ y $R_D(j^*,s^*)$

iii) Aplicamos el algoritmo recursivamente (vuelve a 2 con R_I y R_D)

Random Forest: Es combinar muchos árboles de decisión, y el objetivo es eliminar la influencia de algunos datos y eliminar la influencia de algunas covariables

1) Bagging (Bootstrap Aggregating)

tenemos n datos $D = \{(x_i, y_i)_{i=1}^n\}$.

Remuestreamos n datos de D con reemplazo (es decir tendremos datos repetidos) y a eso le llamamos $\hat{D}$.

Repetimos B veces y tenemos muestras $\hat{D}_1, \hat{D}_2, \dots, \hat{D}_B$.

y hacemos árboles de decisión para c/ conjunto de datos.

C/ árbol se denota a través de su función $\hat{f}_i(x)$ asociada.

y agregamos los resultados:

Regresión $\longrightarrow$ promedio de las predicciones

Clasificación $\longrightarrow$ la mayoría / Moda

2) Reducción de dimensionalidad

en vez de obtener un árbol de decisión directamente en $\hat{D}_b$ primero tomamos un subconjunto aleatorio de las covariables (eg peso, altura, sexo, presión, ojos negros, ojos azules)

$\downarrow m=3$

(Peso, ojos negros, sexo)

Obviamente $m << d$

Nota postclase

Acá es importante que quede claro. Primero se generan los datos resampleados, y luego se contruye el árbol. En la construcción cada nodo elige una muestra aleatorias de covariables en donde va a optimizar. Así, probablemente todas las covariables sean consideradas eventualmente, y si es realmente un buen separador aparecerá. La idea es que no siempre aparezca en la misma posición del árbol. Finalmente, para cada árbol del bosque usamos un conjunto de datos remuestreado diferente