Clase 14: Modelos No-lineales VI

20/Abril/2016

Boosting y Additive Trees.

Idea:

tenemos un problema de clasificación.

$y_i \in \{1, -1\}$

1) Datos Entrenamiento $x_1, \dots, x_n$, $y_1, \dots, y_n$ $\longrightarrow$ Función de predicción G_1

evalúa en datos de entrenamiento.

$G_1 : \mathbb{R}^d \to \{0,1\}$

$G_1(x) \leftarrow$ predicción sobre covariables x.

2) Datos de Entrenamiento $\boxed{\text{Weighted Sample}}$ $\longrightarrow$ Función de predicción G_2

Evaluar.

le asignamos un peso a c/ dato. y vamos a reentrenar con ese peso.

3) Weighted Sample $\longrightarrow$ Función de predicción G_3

Evaluar

$\vdots$

M) Weighted Sample $\longrightarrow$ F de Pred G_M

Evaluar.

El estimador final será de la forma.

$$G(x) = \operatorname{sign}\left(\sum_{m=1}^{M} \alpha_m \underset{\{1,-1\}}{G_m(x)}\right)$$

AdaBoost (M1)

Algoritmo:

1) Darle a c/observación en set de entrenamiento un peso $w_i = \frac{1}{n}$; donde n = tamaño set entrenamiento

2) For $m = 1$ hasta $\boxed{M}$; parámetro del usuario

2.1) Entrenar G_m usando los datos de entrenamiento con pesos.

el clasificador

2.1) $\sum_{i=1}^{n} w_i (y_i - \beta^T x_i)^2$

A veces es directo

En otros casos podemos remuestrear n datos c/repetición con los pesos w_i

2.2) Calculamos el error

$$err = \frac{\sum_{i=1}^{n} w_i \, \mathbb{1}\{y_i \neq G_m(x_i)\}}{\sum_{i=1}^{n} w_i}$$

2.3) Calculamos $\alpha_m = \log\left(\frac{1 - err}{err}\right)$

2.4) Asignamos $w_i \leftarrow w_i \cdot \exp\left(\alpha_m \cdot \mathbb{1}\{y_i \neq G_m(x_i)\}\right)$

para cada (x_i, y_i) en datos entrenamiento.

3. Retornar la función de predicción

$$G(x) = \text{sign}\left(\sum_{m=1}^{M} \alpha_m G_m(x)\right)$$

La idea en dibujo.

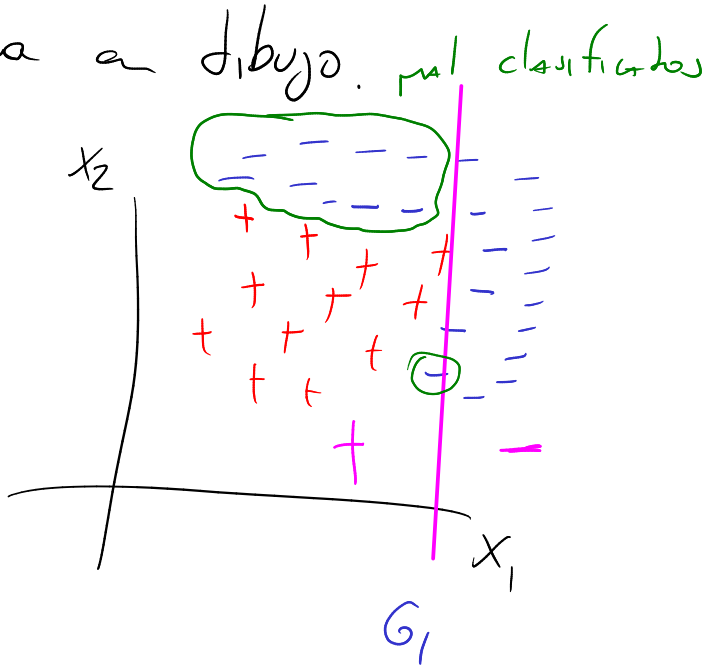

36 datos

10 mal clasificados

$$\frac{10}{36} = \frac{30}{118} \approx 25.5\% = 0.25$$

?

$$err \approx 0.25$$

$$\alpha_1 = \log\left(\frac{1-0.25}{0.25}\right) = \log\left(\frac{0.75}{0.25}\right) = \log(3)$$

$$\Rightarrow \log(3) = 1.09.$$

Iteración 1:

el Nuevo peso de los datos mal clasificados es:

$$\exp(\log(3)) = 3.$$

y los bien clasificados sigue siendo 1.

Iteración 2:

56 puntos

error $\frac{13}{56} \approx 0.23$

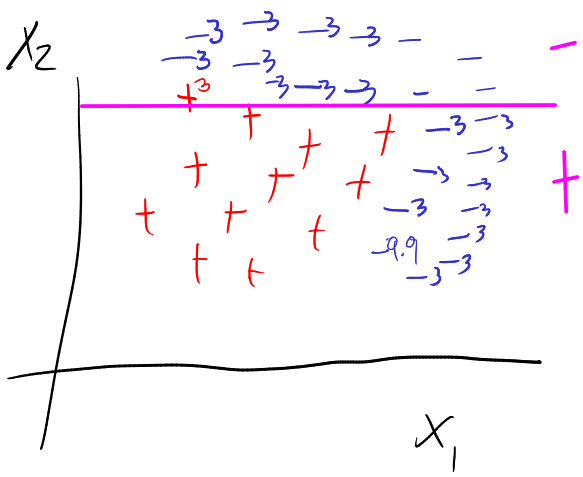

$$\frac{1-err}{err} = 3.3$$

II) De dónde viene el algoritmo?

Lo que queremos es clasificar datos en $+1$ / -1

equivalentemente queremos aprender una función f

$$f: \mathbb{R}^d \to \mathbb{R}$$

tq

$$f(x_i) \gg 0 \quad \text{si } y_i = 1$$

(e.g. 100)

$$f(x_i) \ll 0 \quad \text{si } y_i = -1$$

e.g. -80

Entonces para un dato (x_i, y_i) ¿cuál es una función de pérdida apropiada?

$$L(y_i, f(x_i)) = \exp(-y_i f(x_i))$$

luego queremos minimizar el riesgo

$$\frac{1}{n} \sum_{i=1}^{n} L(y_i, f(x_i)) = \frac{1}{n} \sum_{i=1}^{n} \exp(-y_i f(x_i))$$

Cuál es la familia de estimadores. La familia es

$$f(x) = \sum_{i=1}^{M} \alpha_i G_i(x)$$

donde G_i es un función de predicción que toma valores ± 1

<u>Idea</u>: Agregar predictores uno a uno.

Si tenemos $G_1, \dots G_{m-1}$ ya elegidos.
y tenemos los pesos $\alpha_1, \dots \alpha_{m-1}$ en la iteración
m-1 ya calculados cómo

¿encontrar $\underline{G_m}$ y $\underline{\alpha_m}$?

1)
Para encontrar G_m asumimos que
esto se puede hacer//

Eg: G_m es regresión logística
o el clasificador de split
(Arbol)

2) Nos falta encontrar el peso α_m

$$\alpha_1 G_1(x) + \alpha_2 G_2(x) + \dots + \alpha_m G_m(x)$$

Acá entra la función de pérdida.

$$\min_{(\alpha_m, G_m)} \sum_{i=1}^{n} \exp\left(-y_i\left(f_{m-1}(x_i) + \alpha_m G_m(x_i)\right)\right)$$

donde

$$\underbrace{f_{m-1}(x)}_{\text{conocido}} = \alpha_1 G_1(x) + \alpha_2 G_2(x) + \dots + \alpha_{m-1} G_{m-1}(x)$$

Para resolver el problema de optimización hacemos dos pasos

1) Estimar G_m usando los datos con peso.

2) optimizar α_m asumiendo que ya elegimos G_m y acá derivamos e igualamos a 0.

Entonces nos reducimos al siguiente problema:

$\alpha > 0.$

$$\min_{\alpha, G} \sum_{i=1}^{n} w_i \exp\left(-\boxed{\alpha}\, y_i G(x_i)\right)$$

en el peso se codifica la información de los pasos previos.

Para $\alpha > 0$, G se optimiza solamente mirando los y_i ya que G toma valores -1 o 1 //

Una vez encontrado $\hat{G}$ podemos encontrar α.

$$\min_{\alpha} \sum_{i=1}^{n} w_i \frac{\exp(-\alpha y_i \hat{G}(x_i))}{\exp(-\alpha) \text{ o } \exp(\alpha)}$$

derivamos e igualamos a 0.

$$\sum_{i=1}^{n} w_i \exp(-\alpha) \mathbb{1}_{\{y_i = \hat{G}(x_i)\}}$$

$$+ \sum_{i=1}^{n} w_i \exp(\alpha) \mathbb{1}_{\{y_i \neq \hat{G}(x_i)\}}$$

$$\Rightarrow \frac{\partial}{\partial \alpha} \cdot \Big/ \Big|_{\alpha=0} = -\sum_{i=1}^{n} w_i \mathbb{1}_{\{y_i = \hat{G}(x_i)\}}$$

$$+ \sum_{i=1}^{n} w_i \exp(\alpha) \mathbb{1}_{\{y_i \neq \hat{G}(x_i)\}}$$

$$= 0.$$

$$\Rightarrow \exp(\alpha) = \frac{\sum_{i=1}^{n} w_i \mathbb{1}_{\{y_i = \hat{G}(x_i)\}}}{\sum_{i=1}^{n} w_i \mathbb{1}_{\{y_i \neq \hat{G}(x_i)\}}}$$

Normalizando numerador y denominador

por $\sum_{i=1}^{n} w_i$

nos queda $\exp(\alpha) = \dfrac{1-err}{err}$

donde $err = \dfrac{\sum_{i=1}^{n} w_i \, \mathbb{1}\{y_i \neq \hat{G}(x_i)\}}{\sum_{i=1}^{n} w_i}$