


Boosting y Additive Trees.

Idea:
tenemos
un problema
de clasificación.
 $y_i \in \{1, -1\}$



El estimador final será de la forma.

$$G(x) = \text{sign} \left(\sum_{m=1}^M \alpha_m G_m(x) \right)$$

$\alpha \in \{1, -1\}$

Ada Boost (M1)

Algoritmo:

- 1) Darle a cada observación en set de entrenamiento un peso $w_i = \frac{1}{n}$; donde $n = \text{tamaño set entrenamiento}$
- 2) For $m=1$ hasta M ; parámetro del usuario

2.1) Entrenar G_m el clasificador usando los datos de entrenamiento con pesos.

$$2.1) \sum_{i=1}^n w_i (y_i - \beta^T x_i)^2$$

A veces es directo ↗
En otros casos podemos
remuestrear n datos c/repetición
con los pesos w_i

2.2) Calculamos el error

$$\text{err} = \frac{\sum_{i=1}^n w_i \mathbb{1}\{y_i \neq G_m(x_i)\}}{\sum_{i=1}^n w_i}$$

2.3) Calculamos $\alpha_m = \log\left(\frac{1-\text{err}}{\text{err}}\right)$


2.4) Asignamos $w_i \leftarrow w_i \cdot \exp(\alpha_m \cdot \mathbb{1}\{y_i \neq G_m(x_i)\})$

PARA cada (x_i, y_i)
en datos de entrenamiento.

3. Retornar la función de predicción

$$G(x) = \text{sign}\left(\sum_{m=1}^M \alpha_m G_m(x)\right)$$

ht idea a typo. ml classifier



36 days

NO anal clasifigs
?

$$\frac{10}{36} = \frac{30}{118} \approx 25.5\%$$

$$err \approx 0.75$$

$$\alpha_1 = \log\left(\frac{1-0.25}{0.25}\right) = \log\left(\frac{0.75}{0.25}\right) = \log(3)$$

$$\Rightarrow \log(3) = 1.09.$$


Iteration 1:

el Nuevo peso de
los datos mal clasificados es:

$$\exp(\log(3)) = 3.$$

y los bien clasificados sigue
siendo 1.

Iteraci 2:



→ 56 puntos

error $\frac{13}{56} \approx 0.23$

$$\frac{1 - \text{err}}{\text{err}} = 3.3$$

II) De dónde viene el algoritmo?

Lo que queremos es clasificar datos a ± 1
equivalentemente queremos aprender una función f

$$f: \mathbb{R}^d \rightarrow \mathbb{R}$$

for

$$f(x_i) \gg 0 \quad \text{si } y_i = 1$$

(e.g. 100)

$$f(x_i) \ll 0 \quad \text{si } y_i = -1$$

e.g. -80

Entonces para un dato (x_i, y_i) ¿cuál es una función de pérdida apropiada?

$$L(y_i, f(x_i)) = \exp(-y_i f(x_i))$$

luego queremos minimizar el riesgo

$$\frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) = \frac{1}{n} \sum_{i=1}^n \exp(-y_i f(x_i))$$

Cuál es la familia de estimadores. la familia es

$$f(x) = \sum_{i=1}^M \alpha_i G_i(x)$$

donde G_i es una función de predicción o ± 1

Idea: Agregar predictores uno a uno.

Si tenemos $G_1, \dots, G_{m-1}$ ya elegidos.
y tenemos los pesos $\alpha_1, \dots, \alpha_{m-1}$ en la iteración
 $m-1$ ya calculados como

¿encontrar G_m y α_m ?

1)
Para encontrar G_m ASUMAMOS que
esto se puede hacer //

Eg: G_m es regresión logística
o el clasificador de split
(Arbol)

2) Nos falta encontrar el peso α_m

$$\alpha_1 G_1(x) + \alpha_2 G_2(x) + \dots + \alpha_m G_m(x)$$

↑

Aquí entra la función de pérdidas.

$$\min_{(\alpha_m, G_m)} \sum_{i=1}^n \exp \left(-y_i \left(f_{m-1}(x_i) + \alpha_m G_m(x_i) \right) \right)$$

donde

$$\underline{f_{m-1}(x)} = \alpha_1 G_1(x) + \alpha_2 G_2(x) + \dots + \alpha_{m-1} G_{m-1}(x)$$

$\hookrightarrow$ conocidos.

Para resolver el problema de optimización
hacemos dos pasos

- 1) Estimar G_m usando los datos en peso.
- 2) optimizar α_m asumiendo que ya elegimos G_m y así derivamos e igualamos a 0.

Entonces nos reducimos al siguiente problema:

$$\min_{\alpha, G} \sum_{i=1}^n w_i \exp(-\alpha y_i G(x_i))$$

$\alpha > 0$.

en el peso se codifica

la información de los pasos
previos.

Para $\alpha > 0$, G se optimiza solamente
mirando los y_i ya que G toma
valores -1 o 1 //

Una vez encontrado $\hat{G}$ podemos encontrar
 α .

$$\min_{\alpha} \sum_{i=1}^n w_i \frac{\exp(-\alpha y_i \hat{G}(x_i))}{\exp(-\alpha) + \exp(\alpha)}$$

derivamos e igualamos a 0.

$$\sum_{i=1}^n w_i \exp(-\alpha) \mathbb{1}_{\{y_i = \hat{G}(x_i)\}}$$

$$+ \sum_{i=1}^n w_i \exp(\alpha) \mathbb{1}_{\{y_i \neq \hat{G}(x_i)\}}$$

$$\Rightarrow \frac{\partial}{\partial \alpha} \Big|_{\alpha=0} = - \sum_{i=1}^n w_i \mathbb{1}_{\{y_i = \hat{G}(x_i)\}} + \sum_{i=1}^n w_i \exp(\alpha) \mathbb{1}_{\{y_i \neq \hat{G}(x_i)\}}$$

$$= 0.$$

$$\Rightarrow \exp(\alpha) = \frac{\sum_{i=1}^n w_i \mathbb{1}_{\{y_i = \hat{G}(x_i)\}}}{\sum_{i=1}^n w_i \mathbb{1}_{\{y_i \neq \hat{G}(x_i)\}}}$$

Normalizando numerador y denominador

por $\sum_{i=1}^n w_i$

nos queda

$$\exp(\alpha) = \frac{1 - \text{err}}{\text{err}}$$

donde $\text{err} = \frac{\sum_{i=1}^n w_i \mathbb{1}_{\{y_i \neq \hat{y}(x_i)\}}}{\sum_{i=1}^n w_i}$