

Clase 16: Ada-Boost.

4/ Mayo/2016

Para lo q' queremos hacer conviene tomar la función de pérdida

$$L(x_i, y_i) = \exp(-y_i f(x_i))$$

f predictor en $\mathbb{R}$
y clasificamos por el signo

1) Cómo construimos f ?

a partir de clasificadores simples que toman valores ± 1

$$f(x) = \sum_{m=1}^M \beta_m \underbrace{G_m(x)}$$

; $\beta_m > 0$

$\downarrow$
predictores simple.

2) Cómo estimamos los β 's y los G 's?

De a poco, uno a uno.

Supongamos que tenemos $\beta_1, \dots, \beta_m$ y $G_1, \dots, G_m$ ✓

Queremos encontrar β_{m+1} y G_{m+1}

$$\text{Entonces } f_m(x) = \sum_{k=1}^m \beta_k G_k(x) \leftarrow \begin{array}{l} f \text{ parcial} \\ \text{y conocida} \end{array}$$

$$\text{Así } f_{m+1}(x) = f_m(x) + \underbrace{\beta_{m+1}}_{\text{Desconocido}} \underbrace{G_{m+1}(x)}_{\text{Desconocido}}$$

Usando la función de pérdida
vamos a optimizar

$$\min \sum_{i=1}^n \exp(-y_i f_{m+1}(x_i))$$

pero

$$\sum_{i=1}^n \exp(-y_i f_{m+1}(x_i)) = \sum_{i=1}^n \exp(-y_i f_m(x_i) - y_i \beta_{m+1} G_{m+1}(x_i))$$

$$= \sum_{i=1}^n \underbrace{\exp(-y_i f_m(x_i))}_{w_{i,m}} \cdot \exp(-\beta_{m+1} y_i G_{m+1}(x_i))$$

2) Optimizar.

$\begin{cases} +1 & \text{si predicción es correcta} \\ -1 & \text{si predicción es incorrecta} \end{cases}$

$$\min_{(\beta, G)} \sum_{i=1}^n w_{i,m} \exp(-\beta y_i G(x_i))$$

$$= \min_{(\beta, G)} \sum_{i=1}^n w_{i,m} (\exp(-\beta) \mathbb{1}_{\{y_i = G(x_i)\}} + \exp(\beta) \mathbb{1}_{\{y_i \neq G(x_i)\}})$$

$$= \min_{(\beta, G)} \sum_{i=1}^n w_{i,m} \left(\underbrace{[\exp(-\beta) - \exp(\beta)]}_{C(\beta)} \mathbb{1}_{\{y_i = G(x_i)\}} + \exp(\beta) \right)$$

$$= \min_{(\beta, G)} C(\beta) \sum_{i=1}^n w_{i,m} \mathbb{1}_{\{y_i = G(x_i)\}} + \sum_{i=1}^n w_{i,m} \exp(\beta)$$

Conclusión: i) al mejor G no le importa β

ii) Como $C(\beta)$ es negativo, entonces para encontrar G optimizamos $\max_G \sum_{i=1}^n w_{i,m} \mathbb{1}_{\{y_i = G(x_i)\}}$

iii) Si los predictores son simples, entonces resolver $\max_G \sum_{i=1}^n w_{i,m} \mathbb{1}_{\{y_i = G(x_i)\}}$ debería ser fácil

2.1) Asumimos que resolvimos y encontramos G_{m+1} . Así, volvemos al problema original pero G_{m+1} es conocido

Ahora

$$\min_{\beta} \sum_{i=1}^n w_{i,m} \exp(-\beta y_i G_{m+1}(x_i))$$

Esto es derivar e igualar a zero.

$$\begin{aligned}
 & \sum_{i=1}^n w_{i,m} \exp(-\beta y_i G_{m+1}(x_i)) \\
 &= \sum_{i=1}^n w_{i,m} \cdot \exp(-\beta) \mathbb{1}_{\{y_i = G_{m+1}(x_i)\}} \\
 &\quad + \sum_{i=1}^n w_{i,m} \exp(\beta) \mathbb{1}_{\{y_i \neq G_{m+1}(x_i)\}} \\
 &= \exp(-\beta) \sum_{i=1}^n w_{i,m} (1 - \mathbb{1}_{\{y_i \neq G_{m+1}(x_i)\}}) \\
 &\quad + \exp(\beta) \text{Err}_{m+1} \\
 &= \exp(-\beta) \sum_{i=1}^n w_{i,m} - \exp(-\beta) \text{Err}_{m+1} \\
 &\quad + \exp(\beta) \text{Err}_{m+1}
 \end{aligned}$$

derivando en β

$$\frac{\partial}{\partial \beta} \cdot = -\exp(-\beta) \left(\sum_{i=1}^n w_{i,m} \right) + \exp(-\beta) \text{Err}_{m+1} + \exp(\beta) \text{Err}_{m+1} = 0$$

$$\Rightarrow -\exp(-\beta) + \exp(-\beta) \text{Err}_{m+1}^N + \exp(\beta) \text{Err}_{m+1}^N = 0$$

$$\Rightarrow \exp(-\beta) (1 - \text{Err}_{m+1}^N) = \exp(\beta) \text{Err}_{m+1}^N$$

$$\Rightarrow -\beta + \log(1 - \text{Err}_{m+1}^N) = \beta + \log(\text{Err}_{m+1}^N)$$

$$\Rightarrow \boxed{\beta = \frac{1}{2} \log \left(\frac{1 - \text{Err}_{m+1}^N}{\text{Err}_{m+1}^N} \right)}$$

$$E_n \quad f_{m+1}(x) = f_m + \underbrace{\frac{1}{2} \log \left(\frac{1 - \epsilon}{\epsilon} \right)}_{\alpha_{m+1}} \underbrace{G_{m+1}(x)}_{G_{m+1}(x)}$$