

Definición: ¿Por qué se llama "TAN" a esto?

Regresión lineal: $X \in \mathbb{R}^{d+1}$, $y \in \mathbb{R}$

Datos $(x_i, y_i)_{i=1}^n$

$$X = \begin{pmatrix} -x_1 & - \\ -x_2 & - \\ -x_3 & - \\ \vdots & \vdots \\ -x_n & - \end{pmatrix}$$

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

$$\hat{\beta} = \frac{1}{n} \|X\beta - y\|_2^2$$

$\begin{matrix} \text{p} & & \text{q} \\ \text{m}_x(d+1) & \downarrow & d+1 \end{matrix}$

$d \gg n$.

X
n filas,
d+1 columnas

$$\begin{pmatrix} | & | & | & \dots & | \\ c_0 & c_1 & c_2 & \dots & c_d \\ | & | & | & \dots & | \end{pmatrix} \beta = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

$$\beta_0 c_0 + \beta_1 c_1 + \dots + \beta_d c_d$$

$$\boxed{\hat{\beta} = (X^T X)^{-1} X^T y_n}$$

Algebra lineal

$$X\beta = y \Leftrightarrow X\beta = 0$$

Las soluciones se escriben $\beta = \beta_1 + \beta_2$
 $\beta_1 \in \mathbb{R}^{d+1}$ $\beta_2 \in \mathbb{R}^{d+1}$

don β_1 solución $X\beta_1 = y$

β_2 solución $X\beta_2 = 0$

$$\text{Ker}(X) = \{ \beta : X\beta = 0 \}$$

$$\text{Espacio Filn}(X) = \left\{ X^T \alpha \right\}$$

$\begin{matrix} \text{p} \\ \mathbb{R}^d \end{matrix}$

$$\dim(\text{Ker}(X)) + \dim(\text{EF}(X)) = d+1$$

Si $\mu \in \text{Ker}(X)$ y $v \in \text{EF}(X)$

$$\begin{aligned}\langle v, \mu \rangle &= \langle X^T \alpha, \mu \rangle \quad \text{para algún } \alpha \in \mathbb{R}^n \\ &= (X^T \alpha)^T \mu \\ &= \alpha^T \underbrace{X \mu} = 0\end{aligned}$$

—o.—

De todas las soluciones a $X\beta = y$ cuál es la que tiene menor norma?

$$\begin{aligned}\min \|\beta\|^2 \\ \text{sueto a } X\beta = y\end{aligned}$$

Sea β una solución a $X\beta = y$.

Entonces

$$\beta = \underbrace{\beta_1}_{\in \text{EF}(X)} + \underbrace{\beta_2}_{\in \text{Ker}(X)}$$

$$\|\beta\|^2 = \|\beta_1 + \beta_2\|^2$$

$$= \langle \beta_1 + \beta_2, \beta_1 + \beta_2 \rangle$$

$$= \langle \beta_1, \beta_1 \rangle + \langle \beta_2, \beta_2 \rangle + \cancel{\langle \beta_1, \beta_2 \rangle} + \cancel{\langle \beta_2, \beta_1 \rangle}$$

$$= \|\beta_1\|^2 + \|\beta_2\|^2$$

De aquí deducimos que un β que minimiza $\|\beta\|^2$ sueto a $X\beta = y$ se escribe como

$$\beta = X^T \alpha \in \text{EF}(X)$$

$$\hat{\beta} = \underbrace{(X^T X)^{-1}}_{(d+1) \times (d+1)} \underbrace{X^T y}_{d+1}$$

→ no va a tener inversa.

ahora calculamos gradiente.

$$\nabla L(\beta) = X^T (X\beta - y)$$

$$\beta^{(t+1)} = \beta^t - \eta \underbrace{X^T (X\beta^{(t)} - y)}_{EF(X)}$$

$$\beta^{(0)} = \vec{0} \in EF(X)$$

$$\Rightarrow \beta^{(t)} \in EF(X) \text{ para todo } t, \text{ y luego } \beta^{(\infty)} \in EF(X) \\ \text{y resolvemos } X\beta^{(\infty)} = y$$