

Idea de los métodos de Kernel.

$$\begin{aligned}
 f(x) &= \sum_{i=1}^n \alpha_i \langle x_i, x \rangle \\
 \text{predicador} & \quad \quad \quad \downarrow \text{producto punto en } \mathbb{R}^d \\
 &= \langle \alpha, Xx \rangle \\
 & \quad \quad \quad \downarrow \text{producto punto en } \mathbb{R}^d.
 \end{aligned}$$

$$\hat{R} = \frac{1}{n} \sum_{i=1}^n \left(y_i - \sum_{k=1}^n \alpha_k \langle x_k, x_i \rangle \right)^2$$

$K_{ki} \leftarrow \text{matriz de Gram}$

$$\boxed{\nabla_{\alpha} \hat{R} = 0} \quad \text{y encontramos } \alpha.$$

$$\begin{aligned}
 \frac{\partial}{\partial \alpha_j} \hat{R} &= \frac{1}{n} \sum_{i=1}^n -2 \langle x_j, x_i \rangle \left(y_i - \sum_{k=1}^n \alpha_k \langle x_k, x_i \rangle \right) \\
 &= \frac{1}{n} \left(\sum_{i=1}^n -2 \underbrace{\langle x_j, x_i \rangle}_{K_{ji}} y_i + 2 \sum_{k=1}^n \alpha_k \underbrace{\langle x_j, x_i \rangle}_{K_{ji}} \underbrace{\langle x_i, x_k \rangle}_{K_{ik}} \right) \\
 &= -\frac{2}{n} (Ky)_j + \frac{2}{n} \sum_{i=1}^n \sum_{k=1}^n K_{ji} K_{ik} \alpha_k \\
 &= -\frac{2}{n} (Ky)_j + \frac{2}{n} \sum_{i=1}^n K_{ji} (K\alpha)_i \\
 &= -\frac{2}{n} (Ky)_j + \frac{2}{n} \sum_{i=1}^n (K^2 \alpha)_i
 \end{aligned}$$

gradiente

$$\nabla_{\alpha} \hat{R} = -\frac{2}{n} K y + \frac{2}{n} K^2 \alpha \leftarrow \text{si } K \text{ no tiene inversa, tenemos gradiente.}$$

$$\nabla_{\alpha} \hat{R} = -\frac{2}{n} K y + \frac{2}{n} K^2 \alpha = 0$$

$$\Rightarrow \boxed{K^2 \alpha = K y} \quad \text{ecuación importante}$$

matriz vector = vector vector

Si suponemos que K tiene inversa, entonces:

$$\boxed{\alpha = K^{-1} y} \quad \text{qué es } K?$$

$$K_{ij} = \langle x_i, x_j \rangle$$

2.1) Abstracción K

En nuestro ejemplo $K_{ij} = \langle x_i, x_j \rangle$ pero podría ser otra cosa.

Sí, "Kernel Trick"

$$K_{ij} = \langle \phi(x_i), \phi(x_j) \rangle \quad \text{donde } \phi \text{ es una transformación de los datos.}$$

por así cuando tengo una nueva covariada puedo predecir





$$f(x) = \sum_{i=1}^n \alpha_i \langle \phi(x_i), \phi(x) \rangle \xrightarrow{\text{opt}} \sum_{i=1}^n \hat{\alpha}_i \langle \phi(x_i), \phi(x) \rangle$$

$$\langle x_i, x_j \rangle \xrightarrow{\phi} \langle \phi(x_i), \phi(x_j) \rangle$$

$$\phi: \mathbb{R}^d \rightarrow \mathbb{R}^n$$

$K_{ij} = \langle x_i, x_j \rangle$ en general NO es invertible.

$K_{ij} = \langle \phi(x_i), \phi(x_j) \rangle$ en "general" si es invertible.



3.) Último truco: ϕ se conoce como feature map.

$$K_{ij} = \langle x_i, x_j \rangle \xrightarrow[\text{conocida}]{\phi} \langle \phi(x_i), \phi(x_j) \rangle$$

En vez de encontrar y calcular $\phi(x_i)$

Vamos a definir directamente

$$K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$$

↑
definir directamente $K(x, x')$

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x) \leftarrow \text{Así queda el predictor}$$

Encontrar K no es tan difícil, hay muchos buenos K dando vueltas.

Necesitamos encontrar $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ con buenas propiedades.

3. Kernels:

Un kernel $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ es una función que satisface las propiedades.

1) $K(x, x') = K(x', x) \leftarrow$ simétrica.

2) K es definida-positiva:

Qué significa? Dado puntos $x_1, \dots, x_n \in \mathbb{R}^d$, n arbitrario la matriz

$$K_{ij} = K(x_i, x_j)$$

es definida positiva.

$$\alpha^T A \alpha \geq 0 \quad \forall \alpha \in \mathbb{R}^n \setminus \{0\}$$

Ejemplo: Kernel Gaussiano

$$K(x, x') = \exp \left(-\frac{1}{2\sigma^2} \underbrace{\sum_{i=1}^d (x_i - x'_i)^2}_{\|x - x'\|_2^2} \right) ; \sigma \text{ parámetro length-scale}$$

Kernel Laplace.

$$K(x, x') = \exp \left(-\frac{1}{\sigma} \sum_i |x_i - x'_i| \right) = \exp \left(-\frac{\|x - x'\|_1}{\sigma} \right)$$

Kernel lineal

$$K(x, x') = \langle x, x' \rangle$$

Kernel Polinomial

$$K(x, x') = (c + \langle x, x' \rangle)^d$$

$c > 0$ constante
+ el grado del polinomio

→

Ejercicio: Verifiquemos que el kernel lineal es Kernel:

$$K(x, x') = \langle x, x' \rangle$$

1) Simétrico: claramente $\langle x, x' \rangle = \langle x', x \rangle \checkmark \checkmark$

2) definido positivo: Sea $x_1, \dots, x_n \in \mathbb{R}^d$, consideramos la matriz M

$$M_{ij} = \langle x_i, x_j \rangle$$

Sea $\alpha = (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n \setminus \{0\}$, y hay que verificar que


$$\alpha^T M \alpha > 0$$

$$\begin{aligned} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \underbrace{\langle x_i, x_j \rangle}_{M_{ij}} \alpha_j &= \sum_{i=1}^n \alpha_i \langle x_i, \sum_{j=1}^n \alpha_j x_j \rangle \\ &= \left\langle \sum_{i=1}^n \alpha_i x_i, \sum_{j=1}^n \alpha_j x_j \right\rangle \\ &= \left\| \sum_{i=1}^n \alpha_i x_i \right\|_2^2 \geq 0 \end{aligned}$$

4) Reproducing Kernel Hilbert Spaces

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x)$$

predictor



Definición: RKHS

Un conjunto de funciones $\mathcal{F}$ son un RKHS si $(\mathbb{R}^d \rightarrow \mathbb{R})$

- 1) Son un espacio vectorial
 - 2) Tienen un producto interno
- } Espacio de Hilbert

3) $E_x: \mathcal{F} \rightarrow \mathbb{R}$ ← evaluación en x .

$$E_x(f) \rightarrow f(x)$$

La evaluación en x , E_x , es continua
qué significa?


↓

$$f, g \in \mathcal{F}$$
$$\langle f - g, f - g \rangle_{\mathcal{F}} = \|f - g\|_{\mathcal{F}}^2$$

↙ distancia

⇒ si f y g están cerca en $\|\cdot\|_{\mathcal{F}}$ también tenemos que $f(x)$ y $g(x)$ están cerca.

$$x^m \text{ en } [0,1], m \geq 0$$



$$\overset{\text{finito}}{\downarrow} d(0, x^m) = \int_0^1 |0 - x^m| dx = \int_0^1 x^m dx = \frac{1}{m+1} \rightarrow 0$$

que pasa si evaluamos en $x=1$.

$$0(1) = 0 \leftarrow$$

$$x^m(1) = 1^m = 1 \leftarrow$$

— 0 —

En nuestro caso los predichores se ven así

$$f_{\alpha}(x) = \sum_{i=1}^n \alpha_i K(x_i, x), \quad f_{\beta}(x) = \sum_{i=1}^n \beta_i K(x_i, x)$$

$$f_{\alpha+\beta}(x) = \sum_{i=1}^n (\alpha_i + \beta_i) K(x_i, x)$$

$$f_{\gamma\alpha}(x) = \sum_{i=1}^n (\gamma\alpha_i) K(x_i, x)$$

$$\gamma \in \mathbb{R}$$

es decir

son espacio vectorial