

22 Junio

$K(x, y) \leftarrow \text{kernel}$



$K(x_i, y) \leftarrow$ función en y , que me permite evaluar en x_i
 $\downarrow$
 f_{ij}

$$\langle K(x_i, \cdot), f \rangle_{\mathcal{H}} = f(x_i)$$

$\rightarrow$

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x) \leftarrow \text{familia de predictores}$$

$n=27$



Regresión en Kernels Regularizados

Kernel Ridge Regresión

1) Tenemos un Kernel K y sabemos que existe $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$ cuyo kernel es K .

2) Tenemos datos (x_i, y_i) $x_i \in \mathbb{R}^d$ $y_i \in \mathbb{R}$

me gustaría encontrar f para predecir

$$\min_{f \in \mathcal{H}} \sum_{i=1}^n (y_i - f(x_i))^2 \quad (*)$$

3) Representer Theorem:

La función f que minimiza $(*)$ se escribe como

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x) \quad \text{para algunos valores } \alpha_i \in \mathbb{R}$$

4) Regularizada. usando el producto interno del espacio

$$\min_{f \in \mathcal{H}} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_{\mathcal{H}}^2$$

y el representer Theorem sigue funcionando

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x)$$

entonces

$$\begin{aligned} \|f\|_{\mathcal{H}}^2 &= \langle f, f \rangle_{\mathcal{H}} = \left\langle \sum_{i=1}^n \alpha_i K(x_i, \cdot), \sum_{j=1}^n \alpha_j K(x_j, \cdot) \right\rangle_{\mathcal{H}} \\ &= \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \langle K(x_i, \cdot), K(x_j, \cdot) \rangle_{\mathcal{H}} \end{aligned}$$

$$= \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \underline{K(x_i, x_j)}$$

$$= \alpha^T K \alpha$$

↓
matriz $\sim K(x_i, x_j)$

Así

Así el problema de optimización es

$$\min_{f \in \mathcal{H}} \sum_{i=1}^n (y_i - \underbrace{f(x_i)})^2 + \lambda \|f\|_{\mathcal{H}}^2$$

$$\sum_{j=1}^n \alpha_j K(x_j, x_i)$$

$$RT = \min_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n \left(y_i - \sum_{j=1}^n \underbrace{\alpha_j K(x_j, x_i)}_{K(x_i, x_j) \alpha_j} \right)^2 + \lambda \alpha^T K \alpha$$

↗ matriz

$$= \min_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n (y_i - (K\alpha)_i)^2 + \lambda \alpha^T K \alpha$$

$$\begin{matrix} (K\alpha)_i \\ \uparrow \\ \sum_{j=1}^n K_{ij} \alpha_j \end{matrix}$$

$$\sum_{j=1}^n K_{ij} \alpha_j$$

$$= \min_{\alpha \in \mathbb{R}^n} \langle y - K\alpha, y - K\alpha \rangle_2 + \lambda \alpha^T K \alpha$$

$$= \min_{\alpha \in \mathbb{R}^n} (y - K\alpha)^T (y - K\alpha) + \lambda \alpha^T K \alpha$$

$$= \min_{\alpha \in \mathbb{R}^n} y^T y - 2 \alpha^T K y + \alpha^T K^2 \alpha + \lambda \alpha^T K \alpha$$

Ahora calculemos el gradiente, & igualemos a 0

$$\nabla_{\alpha} (y^T y - 2 \alpha^T K y + \alpha^T K^2 \alpha + \lambda \alpha^T K \alpha) = 0 \quad -2Ky + 2K^2\alpha + 2\lambda K\alpha = 0$$

$$\nabla K^2 \alpha + \lambda \nabla K \alpha - \nabla K y = 0$$

$$\Rightarrow K(K\alpha + \lambda \alpha - y) = 0.$$

$$\Rightarrow (K + \lambda I)\alpha = y$$

$$\Rightarrow \alpha = (K + \lambda I)^{-1} y.$$

y por lo tanto el predictor es

$$f(x) = \sum_{i=1}^n \left[\underbrace{(K + \lambda I)^{-1} y}_\text{vector para predicción}_i \cdot \underbrace{K(x_i, x)}_{\substack{\text{predicción} \\ v_i(x)}} = \langle (K + \lambda I)^{-1} y, v(x) \rangle_2$$